

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN



Báo cáo cuối kỳ: Privacy Protection and Face Recognition

Môn học: Nhận Dạng

Sinh viên thực hiện:

Vũ Tiến Dũng - 23127354

Đinh Xuân Khương - 23127398

Nguyễn Đồng Thanh - 23127538

Giảng viên hướng dẫn:

Lê Hoàng Thái

Võ Thanh Lâm

Nguyễn Thanh Tình

Ngày 20 tháng 4 năm 2026

Mục lục

1	Giới thiệu	1
1.1	Tổng quan về đề án	1
1.2	Đóng góp của thành viên	2
2	Phân tích chương sách	2
2.1	Vấn đề hiện nay	2
2.2	Các giải pháp bảo vệ quyền riêng tư	3
2.3	Các hệ thống bảo vệ quyền riêng tư khuôn mặt	3
2.4	Kỹ thuật chính Blind Vision	4
2.4.1	Kỹ thuật mật mã cốt lõi Blind Vision	4
2.4.2	Mô hình toán học: Đánh giá bộ phân loại an toàn	5
2.4.3	Algorithmic Flow của Blind Vision	5
3	Phân tích bài báo CryptoFace	6
3.1	Giới thiệu	6
3.1.1	Vấn đề hiện nay	6
3.1.2	Ý tưởng chính và hướng tiếp cận	7
3.1.3	Chủ thể phát triển và đối tượng sử dụng	8
3.2	Công trình nền tảng liên quan	8
3.2.1	Mã hóa đồng hình	8
3.2.2	Mạng nơ-ron tích chập đồng hình (Homomorphic CNNs)	9
3.2.3	Từ Blind Vision đến CryptoFace	10
3.3	Phương pháp đề xuất	12
3.3.1	CryptoFace	12
3.3.2	CryptoFaceNet	14
3.3.3	Homomorphic Architecture	16
3.3.4	Mục tiêu kỹ thuật, Phương pháp tiếp cận và Tính hiệu quả	18
3.4	Dữ liệu và thực nghiệm	18
3.4.1	Bộ dữ liệu Huấn luyện	19
3.4.2	Các bộ dữ liệu kiểm thử chuẩn	19
3.4.3	Các bộ dữ liệu kiểm thử chất lượng hỗn hợp	20
3.4.4	Môi trường phần cứng và phần mềm cho thực nghiệm	20
3.4.5	Thiết lập huấn luyện và Siêu tham số	20
3.4.6	Các kỹ thuật đặc biệt	21
3.5	Kết quả và thảo luận	21
3.5.1	Kết quả chính	21
3.5.2	Điểm mạnh	22

3.5.3	Khả năng ứng dụng của kiến trúc	23
3.5.4	Hạn chế và thách thức	23
3.5.5	Kết luận	24
4	CipherFace - Một framework nhẹ hơn	25
4.1	Vấn đề của nhóm	25
4.2	Phương pháp đề xuất	25
4.2.1	Mục tiêu chung với CryptoFace	25
4.2.2	Ý tưởng giải pháp	25
4.2.3	Chi tiết giải pháp	26
4.2.4	Tại sao lại làm như vậy	27
4.3	Dữ liệu và thực nghiệm	28
4.3.1	Dữ liệu thực nghiệm	28
4.3.2	Môi trường phần cứng và phần mềm	28
4.3.3	Thiết lập thực nghiệm và Siêu tham số	29
4.3.4	Thư viện mã hóa	30
4.4	Kết quả thực nghiệm từ bài báo gốc	31
4.4.1	Kết quả chính	31
4.4.2	Điểm mạnh	31
4.4.3	Khả năng ứng dụng của kiến trúc	32
4.4.4	Hạn chế và thách thức	32
5	Thực nghiệm của nhóm với CipherFace	33
5.1	Dữ liệu thực nghiệm	33
5.1.1	Labeled Faces in the Wild	33
5.1.2	Tập dữ liệu mở rộng: Pins Face Recognition (PFR)	33
5.2	Cấu hình thực nghiệm	34
5.2.1	Phần cứng	34
5.2.2	Siêu tham số	34
5.2.3	Thư viện mã hóa	35
5.3	Kết quả thực nghiệm của nhóm	36
5.3.1	Tập LFW	36
5.3.2	Tập PFR	38
6	Cải tiến của nhóm trên FaceNet128d	40
6.1	FaceNet128d	40
6.1.1	Mô tả kiến trúc cơ sở	40
6.1.2	Hạn chế của kiến trúc hiện tại	41
6.1.3	Đề xuất hướng cải tiến: Tích hợp Module CBAM Attention	41

6.2	FaceNet128d cải tiến sử dụng CBAM Attention	42
6.2.1	Động lực cải tiến	42
6.2.2	Cơ chế hoạt động của CBAM	42
6.2.3	Cấu trúc luồng dữ liệu của FaceNet128d_Attention_V2	43
6.3	Thực nghiệm	44
6.3.1	Cấu hình thực nghiệm	44
6.3.2	Dữ liệu thực nghiệm	44
6.3.3	Kết quả thực nghiệm	45
6.4	Đánh giá	45
6.5	Kết luận	46
7	Kết luận và hướng phát triển trong tương lai xa	46
7.1	Kết luận	46
7.2	Hướng phát triển trong tương lai xa	46
8	Lời cảm ơn	48
9	Phụ lục	48
9.1	Ghi chú về cách dùng AI	48
	Tài liệu	51

Danh sách bảng

1	Phân công nhiệm vụ của thành viên	2
2	So sánh phương pháp luận giữa Blind Vision và CryptoFace	11
3	So sánh hiệu năng giữa CryptoFace và các phương pháp FHE khác (Độ phân giải 64×64)	22
4	Kết quả thực nghiệm nhận dạng khuôn mặt trên miền mã hóa của bài báo gốc CipherFace	31
5	Thực nghiệm của nhóm trên tập LFW với số liệu đánh giá 'performance' (ms/it) . .	36
6	So sánh kết quả thực nghiệm trên LFW: Accuracy, Precision, Recall, F1-score và AUC	36
7	Thực nghiệm của nhóm trên tập PFR với số liệu đánh giá 'performance' (ms/it) . .	38
8	So sánh kết quả thực nghiệm trên PFR: Accuracy, Precision, Recall, F1-score và AUC	38
9	So sánh số lượng tham số và hiệu năng giữa các mô hình trên tập kiểm thử	45

Danh sách hình vẽ

1	Quy trình hoạt động của CryptoFace. Ảnh trên: offline; Ảnh dưới: online	13
2	Ảnh bên trái: Huấn luyện bản rõ (cleartext training); Ảnh bên phải: Suy luận trên dữ liệu mã hóa (encrypted inference)	14
3	Các khối Convolutional và cài đặt FHE của nó. Left: ResNet; middle: AESPA; right: CryptoFaceNet.	16
4	Kiến trúc CryptoFaceNet. Top: training; bottom: inference.	17
5	Kiến trúc FaceNet128d (được vẽ bởi Gemini)	40
6	Kiến trúc FaceNet128d sử dụng CBAM Attention (được vẽ bởi Gemini)	42

1 Giới thiệu

1.1 Tổng quan về đề án

Sự bùng nổ của các thiết bị ghi hình kỹ thuật số như camera cá nhân, hệ thống giám sát (CCTV), và các dịch vụ trực tuyến (ví dụ: Google Street View) đã tạo ra những rủi ro nghiêm trọng đối với quyền riêng tư của con người. Khác với dữ liệu văn bản, hình ảnh tuy phi cấu trúc nhưng lại chứa đựng lượng thông tin cực kỳ phong phú về ngoại hình, hành động và thời gian. Hơn nữa, sự phát triển mạnh mẽ của các thuật toán thị giác máy tính hiện nay cho phép khai thác và liên kết dữ liệu hình ảnh dễ dàng như truy vấn một cơ sở dữ liệu.

Trong Chương 27: *Privacy Protection and Face Recognition* của cuốn sách *Handbook of Face Recognition*, các tác giả đã cung cấp một bức tranh toàn cảnh về các giải pháp công nghệ nhằm bảo vệ quyền riêng tư. Các phương pháp trải dài từ việc can thiệp vật lý (Intervention - làm hỏng ảnh chụp trái phép), biên tập lại hình ảnh (Redaction - làm mờ, tạo pixel), cơ chế biên tập kép (Double Redaction), cho đến khử định danh (De-identifying - thuật toán k-same).

Đề án này tập trung vào một phương pháp được đề cập trong chương sách: **(Blind Vision)**. Đây là khuôn mẫu (Paradigm) sử dụng mật mã học cho phép máy tính nhận diện khuôn mặt mà không bao giờ thực sự "nhìn thấy" hình ảnh thực tế hay biết được danh tính thực của người dùng.

Kế thừa hệ tư tưởng này trong kỷ nguyên Deep Learning, nhóm lựa chọn nghiên cứu và đối chiếu với bài báo hiện đại hàng đầu: **"CryptoFace: End-to-End Encrypted Face Recognition"** [1] được công bố tại CVPR 2025. Bên cạnh đó, để có thực hiện hóa việc chạy thực nghiệm và hỗ trợ thông tin cho bài báo CryptoFace, nhóm sẽ đọc thêm bài báo **CipherFace: A Fully Homomorphic Encryption-Driven Framework for Secure Cloud-Based Facial Recognition** [16].

Thông qua đó, đề án của nhóm sẽ minh họa luồng dữ liệu bảo mật từ lý thuyết sơ khai của Blind Vision đến hệ thống mã hóa đầu cuối toàn diện của CryptoFace và CipherFace .

1.2 Đóng góp của thành viên

Họ và Tên	Nhiệm vụ	Hoàn thành
Vũ Tiến Dũng	Giới thiệu, phân tích chương sách, khả năng ứng dụng, viết CipherFace, chạy thực nghiệm.	100%
Đinh Xuân Khương	Giới thiệu bài báo, phương pháp đề xuất, Kết quả và so sánh, viết CipherFace, chạy thực nghiệm, cải tiến mô hình.	100%
Nguyễn Đồng Thanh	Công trình liên quan, hạn chế và thách thức, hướng phát triển, viết CipherFace, chạy thực nghiệm.	100%

Bảng 1: Phân công nhiệm vụ của thành viên

2 Phân tích chương sách

2.1 Vấn đề hiện nay

Sự bùng nổ của hình ảnh kỹ thuật số từ các thiết bị như camera cá nhân, điện thoại di động, camera giám sát và truyền hình đã tạo ra những rủi ro lớn về quyền riêng tư. Sự khác biệt cốt lõi nằm ở bản chất của dữ liệu hình ảnh: dù phi cấu trúc và khó quản lý hơn văn bản, hình ảnh lại chứa đựng lượng thông tin cực kỳ phong phú về ngoại hình, hành vi, thông tin cá nhân và vị trí theo thời điểm của các cá nhân.

Trước đây, việc lạm dụng hình ảnh bị hạn chế do rào cản về mặt xử lý thủ công. Tuy nhiên, sự trỗi dậy của các thuật toán thị giác máy tính hiện đại đã cho phép tự động hóa việc trích xuất, khai thác và liên kết dữ liệu hình ảnh dễ dàng như truy vấn một cơ sở dữ liệu thông thường. Điều này dẫn đến những lo ngại sâu sắc về quyền riêng tư trong nhiều lĩnh vực:

- **Giám sát video (CCTV):** Hệ thống chuyển từ răn đe thụ động sang giám sát liên tục, tự động nhận diện khuôn mặt và theo dõi hành vi xuyên suốt các mạng lưới camera.
- **Hình ảnh y tế:** Các cơ sở dữ liệu điện tử chứa ảnh bệnh nhân cần được bảo vệ danh tính nghiêm ngặt để tránh rò rỉ, trong khi vẫn phải giữ nguyên giá trị cho nghiên cứu và giảng dạy.
- **Chia sẻ ảnh trực tuyến và Chế độ xem phổ:** Các nền tảng lưu trữ hàng tỷ bức ảnh (như Facebook, Flickr) và các dịch vụ bản đồ (như Google Street View) có khả năng tự động gắn thẻ và lập chỉ mục khuôn mặt trên quy mô toàn cầu, đe dọa trực tiếp đến quyền riêng tư của người dùng.

2.2 Các giải pháp bảo vệ quyền riêng tư

Để đối phó với những rủi ro trên, nhiều giải pháp công nghệ đã được đề xuất nhằm bảo vệ quyền riêng tư trong hình ảnh và video.

- **Intervention (Can thiệp vật lý):** Đây là phương pháp ngăn chặn việc chụp ảnh trái phép ngay từ đầu. Các thiết bị chống lại việc quay/chụp lén - "anti-paparazzi" sử dụng đặc tính phản xạ ngược để phát hiện ống kính camera đang chĩa vào, sau đó tự động chiếu một tia sáng mạnh (flash) bằng máy chiếu kỹ thuật số để làm hỏng bức ảnh chuẩn bị được ghi lại.
- **Redaction và Double Redaction :**
 - *Redaction:* Sử dụng thị giác máy tính để phát hiện các vùng nhạy cảm (như khuôn mặt) và làm biến dạng chúng bằng các kỹ thuật như làm mờ (blurring), tạo pixel (pixelating), làm xáo trộn (scrambling) hoặc hoán vị pixel.
 - *Double Redaction:* Là cơ chế bảo vệ linh hoạt và an toàn hơn, trong đó dữ liệu được bảo vệ ngay từ cấp độ camera. Luồng dữ liệu mặc định truyền đi trong hệ thống là luồng đã bị che khuất. Các luồng dữ liệu thô chứa thông tin nhạy cảm được mã hóa tách biệt và chỉ những người dùng có đủ thẩm quyền, sở hữu khóa giải mã mới có thể kết hợp lại để xem hình ảnh gốc.
- **Cryptographically Secure Processing:** Phương pháp này giải quyết bài toán hợp tác xử lý dữ liệu giữa hai bên **không** tin tưởng nhau. Việc mã hóa là bắt buộc để cho phép một bên (sở hữu thuật toán) thực thi các phép tính trên dữ liệu của bên kia (sở hữu hình ảnh) mà không làm lộ dữ liệu thô cũng như không làm rò rỉ cấu trúc thuật toán.

Kỹ thuật nổi bật nhất trong hướng tiếp cận này là **Blind Vision**. Giao thức này sử dụng mật mã học để cho phép máy tính nhận diện khuôn mặt mà không cần "nhìn thấy" hình ảnh thực tế. Dựa trên nguyên lý tính toán đa bên an toàn (**Secure Multi-party Computation - SMPC**), các phép toán phân loại được chuyển đổi sang miền mã hóa, đảm bảo Alice (đóng vai client) và Bob (đóng vai Server) cùng tính toán mà không để lộ thông tin nhạy cảm.
- **Privacy Policies:** Các phương pháp này liên quan đến việc xác định ai cần được bảo vệ trong môi trường công cộng. Người dùng có thể mang theo các thiết bị phát tín hiệu hoặc sử dụng các dấu hiệu trực quan (như mũ, áo khoác) để thông báo cho hệ thống camera tự động biết rằng họ muốn được áp dụng chính sách làm mờ khuôn mặt hoặc ngược lại.

2.3 Các hệ thống bảo vệ quyền riêng tư khuôn mặt

Các công nghệ bảo vệ quyền riêng tư đã được cụ thể hóa thành các hệ thống chuyên dụng để giải quyết những thách thức thực tiễn.

- **Google Street View:** Hệ thống này giải quyết bài toán ẩn danh trên quy mô dữ liệu khổng lồ của hình ảnh đường phố. Thuật toán sử dụng một bộ dò tìm khuôn mặt cửa sổ trượt (sliding-window face detector) kết hợp với mạng nơ-ron để phân loại các vùng ảnh. Mọi khuôn mặt và biển số xe được phát hiện sẽ bị làm mờ bằng Gaussian và thêm nhiễu. Quá trình biên tập này được thiết kế để không thể đảo ngược, đảm bảo tính trực quan cho người xem biết rằng hình ảnh đã được che khuất.
- **De-identifying Face Images (Khử định danh khuôn mặt):** Hệ thống này đặc biệt hữu ích cho các cơ sở dữ liệu y tế hoặc không gian truyền thông, nơi cần ẩn danh tính nhưng vẫn phải giữ lại biểu cảm hoặc hướng nhìn. Bằng cách sử dụng không gian Eigenface hoặc các Active Appearance Models, hệ thống áp dụng thuật toán *k-same* để tạo ra một khuôn mặt trung bình được pha trộn từ nhiều người khác nhau. Kết quả là tạo ra một khuôn mặt mới không thể truy ngược lại một cá nhân cụ thể nào, nhưng vẫn bảo tồn được các yếu tố phi danh tính như nét mặt đau đớn (đối với bệnh nhân).
- **Blind Face Recognition:** Đây là hệ thống triển khai thực tế của các giao thức xử lý tín hiệu bảo mật bằng mật mã. Hệ thống có khả năng thực hiện phép chiếu một hình ảnh truy vấn (query image) lên không gian eigenvector và tính toán khoảng cách đến các khuôn mặt đã đăng ký hoàn toàn trong môi trường mã hóa. Quá trình này đảm bảo bên truy vấn không phải tiết lộ ảnh gốc, và bên lưu trữ cũng không phải lộ cơ sở dữ liệu khuôn mặt.

2.4 Kỹ thuật chính Blind Vision

Để hiểu rõ nền tảng của các hệ thống nhận dạng bảo mật, chúng ta cần đi sâu vào mô hình toán học và kiến trúc kỹ thuật của phương pháp **Blind Vision** [2] (Avidan & Butman, 2006) được giới thiệu trong chương sách. Blind Vision thiết lập một *Paradigm* mang tính phân quyền và "không tin tưởng" (Zero-trust) giữa hai thực thể:

- **Alice (Client):** Người sở hữu bức ảnh khuôn mặt cần xác thực nhưng muốn bảo vệ quyền riêng tư, tuyệt đối không gửi ảnh thô ra ngoài[2].
- **Bob (Server):** Hệ thống sở hữu bộ phân loại và cơ sở dữ liệu nhận dạng, muốn bảo vệ quyền sở hữu trí tuệ (trọng số thuật toán) của mình[2].

2.4.1 Kỹ thuật mật mã cốt lõi Blind Vision

Blind Vision hoạt động dựa trên nguyên lý **Tính toán đa bên an toàn (SMPC)**. Hai công cụ mật mã chính được sử dụng bao gồm:

1. **Mạch xáo trộn (Yao's Garbled Circuits):** Bob chuyển đổi các hàm tính toán (như phép nhân, phép cộng) thành một mạng lưới các cổng logic (AND, OR, NOT) đã được mã hóa.

Alice đưa dữ liệu của mình qua mạch này để lấy kết quả mà không thể giải mã được cấu trúc bên trong của mạch.

2. **Chuyển giao không nhận biết (Oblivious Transfer - OT):** Một giao thức cho phép Alice nhận các tham số tương ứng với dữ liệu của mình từ Bob, nhưng Bob hoàn toàn không biết Alice đã chọn lấy phần dữ liệu nào.

2.4.2 Mô hình toán học: Đánh giá bộ phân loại an toàn

Trong Blind Vision, bài toán nhận diện khuôn mặt được đơn giản hóa thành việc đánh giá một bộ phân loại tuyến tính (như Adaboost) dựa trên phép **Tích vô hướng**. Quyết định nhận dạng được biểu diễn qua hàm:

$$f(x) = \text{sign} \left(\sum_{i=1}^n w_i \cdot x_i - \theta \right) \quad (1)$$

Trong đó:

- $\vec{x} = [x_1, x_2, \dots, x_n]$ là vector đặc trưng trích xuất từ ảnh của Alice.
- $\vec{w} = [w_1, w_2, \dots, w_n]$ là vector trọng số thuộc về Bob.
- θ là ngưỡng quyết định (Threshold).

Thay vì tính toán trực tiếp, hệ thống áp dụng cơ chế **Additive Secret Sharing**. Alice và Bob tự chia nhỏ các phần tử của vector thành các mảnh (được gọi là shares) trên một trường hữu hạn modulo M :

$$\begin{aligned} x_i &= x_{i,A} + x_{i,B} \pmod{M} \\ w_i &= w_{i,A} + w_{i,B} \pmod{M} \end{aligned}$$

Thông qua giao thức OT và Garbled Circuits, cả hai bên cùng phối hợp tính toán ra tích vô hướng mà không bên nào khôi phục được giá trị $\vec{x}$ hay $\vec{w}$ của đối phương.

2.4.3 Algorithmic Flow của Blind Vision

Kiến trúc vận hành của phương pháp được chia làm các bước:

1. **Giai đoạn Tiền xử lý:** Do giới hạn tính toán của SMPC, Alice sử dụng bộ lọc HoG (Histogram of Oriented Gradients) để tìm nhanh các vùng cửa sổ (windows) có khả năng chứa khuôn mặt, nhằm giảm thiểu lượng dữ liệu phải đưa vào miền mã hóa.
2. **Giai đoạn Mã hóa:** Alice che giấu (mask) các vector đặc trưng của mình thành các "shares".
3. **Giai đoạn Tính toán an toàn:** Bob gửi Garbled Circuit cho Alice. Alice dùng OT để lấy các khóa tương ứng và chạy mạch logic.

4. **Giai đoạn Trả kết quả:** Mạch logic nhả ra kết quả nhị phân (Có/Không phải khuôn mặt mục tiêu). Chỉ duy nhất Alice (người chạy mạch cuối cùng) biết được kết quả này.

Mô hình toán học và kiến trúc này của Blind Vision chính là viên gạch nền tảng, đặt ra bài toán kinh điển về bảo mật sinh trắc học mà các nghiên cứu hiện đại như CryptoFace sau này kế thừa và phát triển.

3 Phân tích bài báo CryptoFace

3.1 Giới thiệu

Nhận diện khuôn mặt đóng vai trò trung tâm trong nhiều ứng dụng xác thực, an ninh và cá nhân hóa hiện nay. Tuy nhiên, công nghệ này đang đối mặt với những rủi ro nghiêm trọng về quyền riêng tư, đặc biệt là mối đe dọa từ việc truy cập trái phép vào dữ liệu sinh trắc học nhạy cảm. Để giải quyết thách thức này, tác giả giới thiệu CryptoFace, **hệ thống nhận diện khuôn mặt mã hóa đầu-cuối đầu tiên** sử dụng Mã hóa đồng hình đồng hình toàn phần (Fully Homomorphic Encryption - FHE) để giải quyết một số vấn đề trong việc bảo mật sắp nêu dưới đây.

3.1.1 Vấn đề hiện nay

Trong bài toán nhận diện khuôn mặt:

- **Tính bất biến của dữ liệu sinh trắc học:** Khác với mật khẩu, dữ liệu sinh trắc học nói chung và dữ liệu khuôn mặt nói riêng là không thể thay đổi. Nếu thông tin này bị lộ, người dùng sẽ đối mặt với nguy cơ bị đánh cắp danh tính và xâm phạm quyền riêng tư vĩnh viễn mà không có cách nào khác để khắc phục.
- **Rủi ro từ các thực thể trong hệ thống:** Các hệ thống FR bao gồm ba thành phần nhạy cảm: hình ảnh đầu vào, bộ trích xuất đặc trưng (sử dụng mạng nơ-ron), và cơ sở dữ liệu tham chiếu. Bất kỳ thành phần nào bị truy cập trái phép cũng dẫn đến rủi ro giám sát hoặc chiếm đoạt thông tin trái phép.
- **Áp lực từ quy định pháp lý:** Do tính nhạy cảm cao, việc thu thập, lưu trữ và sử dụng dữ liệu sinh trắc học bị kiểm soát gắt gao bởi các bộ luật như GDPR. Điều này tạo ra thách thức lớn cho các nhà phát triển trong việc xây dựng hệ thống vừa hiệu quả vừa tuân thủ pháp luật một cách nghiêm ngặt.

Trong toàn bộ hệ thống nhận diện khuôn mặt an toàn:

- **Rủi ro từ hai phía:** Khách hàng có thể tìm cách đánh cắp dữ liệu từ cơ sở dữ liệu của máy chủ hoặc tạo mẫu giả để đánh lừa hệ thống. Ngược lại, máy chủ có thể khai thác dữ liệu khách hàng để trích xuất thông tin sinh trắc học hoặc các thuộc tính nhạy cảm như tuổi tác,

giới tính và chủng tộc. Một trong hai điều này đều gây ảnh hưởng lớn cho tính an toàn của hai bên.

- **Hạn chế của giải pháp hiện tại:** Các hệ thống hiện nay thường chỉ mã hóa các đặc trưng sau khi đã trích xuất. Điều này buộc khách hàng phải tự thực hiện việc trích xuất đặc trưng tại máy cá nhân (local) mà không thể ủy thác cho máy chủ, làm giảm tính tiện dụng của hệ thống.
- **Lỗ hổng bảo mật:** Việc chỉ bảo vệ đặc trưng khuôn mặt là chưa đủ, vì hệ thống vẫn dễ bị tổn thương trước các cuộc tấn công phục hồi mẫu (template recovery attack [3]), cho phép kẻ xấu suy luận ngược lại các đặc trưng gốc được lưu trữ trên máy chủ.
- **Thiếu bảo vệ đầu-cuối:** Các nghiên cứu khác thường chỉ tập trung vào từng vấn đề riêng lẻ như **tấn công đối nghịch** (adversarial attacks [7]), **tấn công quan sát** (viewing attacks [14]) hay **rò rỉ thông tin** (information leakage [12]), thay vì cung cấp một giải pháp bảo mật toàn diện và có thể chứng minh được từ hình ảnh thô đến kết quả cuối cùng.

Để giải quyết các vấn đề này, nhóm tác giả đã đề xuất các mục tiêu và hướng tiếp cận tương ứng.

3.1.2 Ý tưởng chính và hướng tiếp cận

Ý tưởng chính

Ý tưởng cốt lõi của CryptoFace là xây dựng một hệ thống nhận diện khuôn mặt mã hóa đầu-cuối (end-to-end) sử dụng Mã hóa đồng hình toàn phần (FHE).

- **Bảo mật tuyệt đối:** Mọi dữ liệu từ ảnh thô, đặc trưng cho đến kết quả đối khớp đều được giữ ở trạng thái mã hóa trong suốt quá trình xử lý.
- **Không cần giải mã:** Máy chủ có thể thực hiện trích xuất đặc trưng và so khớp trực tiếp trên dữ liệu mã hóa mà không bao giờ nhìn thấy thông tin gốc, giúp loại bỏ hoàn toàn nguy cơ rò rỉ dữ liệu sinh trắc học nhạy cảm.

Tuy nhiên, có những thách thức được đặt ra để đạt được mục tiêu này, cụ thể như sau:

- Việc đánh giá Homomorphic của mạng tích chập (CNNs) hiện tại tốn quá nhiều chi phí, phần lớn do độ sâu nhân (multiplicative depth) của CNNs.
- Mặc dù đã có các phương pháp giải quyết được vấn đề trên, tuy nhiên chỉ dừng lại ở các ảnh có độ phân giải thấp. Các ảnh có độ phân giải lớn hơn, thì các phương pháp này chưa giải quyết được.
- Bài toán nhận dạng yêu cầu tính toán độ tương đồng Cosine, tuy nhiên việc tính toán này không thể được thực hiện trực tiếp trong môi trường FHE.

- Có một số giải pháp cho việc tính toán Cosine trên, đó chính là chuẩn hóa các đặc trưng trước khi tiến hành mã hóa, nhưng việc này cũng sẽ gây ra tốn nhiều thời gian.

Hướng tiếp cận

Để đạt được mục tiêu và giải quyết những vấn đề trên, tác giả đã đề xuất các hướng tiếp cận:

- **Kiến trúc CryptoFaceNet (CNNs dựa trên Patch):** Thay vì xử lý toàn bộ ảnh lớn (vốn tiêu tốn rất nhiều tài nguyên FHE), CryptoFace chia hình ảnh thành các patch nhỏ không chồng lấp. Mỗi patch được xử lý độc lập bởi một mạng tích chập nông (shallow patch CNN - hay PCNN [10]).
- **Tối ưu hóa khối tích chập và hàm kích hoạt:** Nhóm tác giả thiết kế lại các khối ResNet thông thường thành các khối CryptoFaceNet tối ưu độ sâu:
 - Sử dụng hàm kích hoạt đa thức Hermite bậc thấp để thay thế cho hàm ReLU (vốn không tương thích với FHE).
 - Hòa trộn các hệ số của hàm kích hoạt vào trọng số của lớp tích chập để tiết kiệm thêm các mức tính toán nhân (multiplicative levels).
- **Xấp xỉ đa thức cho độ tương đồng Cosine:** Vì hàm Cosine không thể tính trực tiếp bằng FHE, nhóm nghiên cứu đã thiết kế một phương pháp xấp xỉ đa thức dựa trên phân phối dữ liệu (distribution-aware) để chuẩn hóa đặc trưng (L2 normalization) và tính điểm tương đồng một cách hiệu quả.

3.1.3 Chủ thể phát triển và đối tượng sử dụng

- **Nhóm nghiên cứu:** Giải pháp được nghiên cứu và phát triển bởi Wei Ao và Vishnu Naresh Boddeti thuộc Đại học Bang Michigan (Michigan State University). Công trình này được công bố chính thức tại hội nghị CVPR 2025.
- **Đối tượng hưởng đến:** Các tổ chức yêu cầu bảo mật sinh trắc học mức độ cao như ngân hàng, dịch vụ tài chính, cơ quan hành chính công và các hệ thống quản lý danh tính tuân thủ quy định GDPR...

3.2 Công trình nền tảng liên quan

3.2.1 Mã hóa đồng hình

Mã hóa đồng hình (Homomorphic Encryption - HE) là một lớp các lược đồ mật mã cho phép thực hiện các phép toán trực tiếp trên dữ liệu đã mã hóa mà không cần giải mã trước đó. Các hệ thống HE hiện đại thường dựa trên bài toán Học có lỗi (Learning with Errors - LWE) hoặc Ring-LWE, cung cấp khả năng bảo mật hậu lượng tử mạnh mẽ.

Trong bối cảnh mạng nơ-ron nhân tạo, bài báo nhấn mạnh việc sử dụng lược đồ **CKKS** [6, 5] vì khả năng hỗ trợ số học xấp xỉ trên số thực và số phức. Quá trình mã hóa và giải mã cơ bản trong CKKS được định nghĩa như sau:

$$\begin{cases} \text{Encrypt}(m, pk) = (c_0, c_1) = c \\ \text{Decrypt}(c, sk) = c_0 + \langle c_1, sk \rangle = m + e \end{cases} \quad (2)$$

Trong đó:

- m : Thông điệp bản rõ (plaintext).
- pk : Khóa công khai (public key) dùng để mã hóa.
- sk : Khóa bí mật (secret key) dùng để giải mã.
- $c = (c_0, c_1)$: Bản mã (ciphertext) dưới dạng một cặp đa thức.
- $\langle \cdot, \cdot \rangle$: Phép toán tích vô hướng (dot product).
- e : Nhiễu hệ thống (encryption noise) phát sinh trong quá trình mã hóa.

Lược đồ này hỗ trợ ba phép toán chính trên miền bản mã:

- **Phép cộng ($\oplus$)**: Cộng trực tiếp hai bản mã hoặc một bản mã với một bản rõ.
- **Phép nhân ($\otimes$)**: Nhân hai bản mã hoặc một bản mã với một bản rõ.
- **Phép quay (Rot)**: Thực hiện quay vòng các phần tử trong vector bản mã.

Rào cản lớn nhất của HE là **độ sâu nhân**. Mỗi phép nhân bản mã làm tăng mức nhiễu và tiêu tốn một level l của bản mã. Khi cạn kiệt các mức này ($l = 0$), việc giải mã sẽ thất bại. Dựa trên cách xử lý giới hạn này, HE được chia thành hai loại:

- **LHE (Leveled Homomorphic Encryption)**: Không sử dụng kỹ thuật làm mới bản mã, số lượng phép nhân bị giới hạn bởi tham số ban đầu L .
- **FHE (Fully Homomorphic Encryption)**: Sử dụng thao tác *bootstrapping* để làm mới mức độ nhiễu, cho phép tính toán với độ sâu vô hạn. Tuy nhiên, *bootstrapping* cực kỳ đắt đỏ, chậm hơn các phép toán thông thường khoảng hai bậc đại lượng.

3.2.2 Mạng nơ-ron tích chập đồng hình (Homomorphic CNNs)

Homomorphic CNNs (hay HCNNs) là các mô hình CNN được thiết kế để tương thích với các phép toán giới hạn của HE. HCNNs thường được phân loại thành LHENets (mạng nông, không dùng bootstrapping) và FHENets (mạng sâu hơn, có sử dụng bootstrapping như MPCNN hoặc AutoFHE).

Việc tối ưu hóa HCNNs tập trung vào hai chiến lược then chốt:

Đóng gói dữ liệu (Packing for Convolutions)

Để giảm thiểu chi phí tính toán trên tensor 3 chiều, các kỹ thuật đóng gói như *Multiplexed Packing* được áp dụng. Phương pháp này tận dụng các khe trống (slots) trong đa thức vòng để nén dữ liệu từ nhiều kênh khác nhau:

$$x^{(M)} = [x, x, \dots, x] \quad (3)$$

Trong đó:

- x : Vector dữ liệu đầu vào có kích thước d .
- $M = \lfloor \frac{N}{2d} \rfloor$: Số lượng bản sao có thể đóng gói vào một bản mã duy nhất.
- N : Bậc của đa thức vòng (cyclotomic polynomial degree).

Kỹ thuật này cho phép tính toán song song các kênh, giúp tăng tốc độ suy luận đáng kể.

Polynomial Activation

Do HE không thể thực hiện các hàm phi tuyến tính không liên tục như ReLU, HCNNS sử dụng các đa thức bậc thấp để xấp xỉ. CryptoFace sử dụng đa thức Hermite (HerPN) để giảm độ sâu nhân xuống còn 2 mức cho mỗi hàm kích hoạt. Một hàm kích hoạt đa thức bậc 2 có dạng:

$$P(x) = ax^2 + bx + c \quad (4)$$

Trong đó:

- x : Giá trị đầu vào sau lớp tích chập.
- a, b, c : Các hệ số đa thức được tối ưu hóa để mô phỏng hành vi của hàm ReLU.
- $P(x)$: Giá trị kích hoạt đầu ra trong miền bản mã.

Ngoài ra, để thực hiện nhận dạng khuôn mặt đầu-cuối, CryptoFace còn giới thiệu xấp xỉ đa thức cho chuẩn hóa l_2 để tính toán độ tương đồng cosine mà không cần giải mã.

3.2.3 Từ Blind Vision đến CryptoFace

1. Sự kế thừa và nền móng

Blind Vision (2006) được coi là nghiên cứu đặt nền móng cho paradigm nhận diện khuôn mặt và thị giác máy tính trên dữ liệu mã hóa. Nghiên cứu này thiết lập kịch bản kinh điển giữa hai thực thể: **Alice** (người sở hữu dữ liệu nhạy cảm) và **Bob** (người sở hữu thuật toán nhận diện). Mục tiêu cốt lõi là Alice có thể sử dụng dịch vụ của Bob mà không tiết lộ nội dung hình ảnh, đồng thời Bob bảo vệ được sở hữu trí tuệ của thuật toán.

CryptoFace (2025) kế thừa hoàn toàn paradigm "Alice vs Bob" này để giải quyết các rủi ro về quyền riêng tư trong dữ liệu sinh trắc học hiện đại. Điểm chung cốt lõi giữa hai phương pháp là việc sử dụng các khái niệm toán học để thực hiện phép tính trên dữ liệu được che giấu:

- **Điểm chung về bài toán:** Cả hai đều đối mặt với sự mâu thuẫn giữa việc che giấu dữ liệu và nhu cầu suy luận từ các mô hình học máy.
- **Kế thừa về hạ tầng toán học:** *Blind Vision* sử dụng các giao thức tính toán đa bên an toàn như Secure Dot Product và bài toán Secure Millionaire. *CryptoFace* hiện đại hóa điều này bằng cách chuyển đổi các lớp tích chập của mạng nơ-ron sâu thành các phép toán tương đương trên miền FHE.

2. Phân tích sự khác biệt về phương pháp luận

Mặc dù có chung mục tiêu bảo vệ quyền riêng tư, cách tiếp cận của *Blind Vision* và *CryptoFace* có sự khác biệt rõ rệt về mặt kỹ thuật và khả năng ứng dụng thực tế:

Đặc điểm	Blind Vision (2006)	CryptoFace (2025)
Công cụ mật mã	Sử dụng SMPC và OT.	Sử dụng FHE, cụ thể là lược đồ CKKS.
Mô hình thị giác	Dựa trên thuật toán Viola-Jones (đặc trưng Haar-like) và hàm băm HoG.	Dựa trên Deep CNN với kiến trúc CryptoFaceNet.
Khả năng ủy quyền	Yêu cầu Alice và Bob phải tương tác liên tục qua lại để hoàn thành giao thức.	Alice gửi ảnh đã mã hóa lên server; server có thể tự tính toán độc lập (Outsourced).
Hiệu suất	Tuyến tính với số lượng cửa sổ dò tìm, xử lý rất chậm (vài phút cho một cửa sổ 24×24).	Hỗ trợ xử lý song song, độ trễ gần như không phụ thuộc vào độ phân giải ảnh nhờ kiến trúc PCNN.
Tính bảo mật	Dựa trên giả định thực thể "honest-but-curious".	Cung cấp mức độ bảo mật mạnh mẽ hơn, có khả năng chống lại các cuộc tấn công hậu lượng tử.

Bảng 2: So sánh phương pháp luận giữa Blind Vision và CryptoFace

Tóm lại, nếu Blind Vision là người mở đường với các giao thức tương tác sơ khai, thì CryptoFace là bước tiến nhảy vọt khi kết hợp sức mạnh của FHE và Deep Learning để tạo ra một hệ thống nhận diện khuôn mặt mã hóa đầu-cuối thực thụ.

3.3 Phương pháp đề xuất

3.3.1 CryptoFace

CryptoFace tận dụng khả năng học biểu diễn của các mạng CNNs để trích xuất các đặc trưng có tính phân biệt cao, dưới đây sẽ là một số khái niệm để người đọc có thể hiểu rõ hơn về bài toán.

- **Trích xuất đặc trưng:** Với ảnh khuôn mặt x , mạng nơ-ron f_ω , w là các trọng số có thể học của mô hình, sẽ tạo ra vector đặc trưng (d là số chiều của vector đặc trưng).

$$y = f_\omega(x) \in \mathbb{R}^d.$$

- **Đo lường độ tương đồng:** Để so sánh hai khuôn mặt x_1 và x_2 , hệ thống tính toán điểm số dựa trên khoảng cách giữa hai đặc trưng đã được chuẩn hóa:

$$\text{Score}(y_1, y_2) = \left\| \frac{y_1}{\|y_1\|} - \frac{y_2}{\|y_2\|} \right\|^2 = 2 - 2 \frac{y_1^\top y_2}{\|y_1\| \|y_2\|}.$$

- **Quyết định đôi khớp:** Nếu hai gương mặt được coi là một người khi $\text{Score}(y_1, y_2)$ nhỏ hơn một ngưỡng T (Threshold). Vậy nên, kết quả được xác định qua hàm $\text{Match}()$ dưới đây:

$$\text{Match}(y_1, y_2) = \text{Score}(y_1, y_2) - T. \quad (5)$$

Nếu kết quả là số âm, hai khuôn mặt được coi là cùng một người.

Chiến thuật huấn luyện

Một mạng nơ-ron $f_\omega(\cdot)$ cho bài toán nhận dạng khuôn mặt được huấn luyện trên tập dữ liệu $\mathcal{X}$ gồm M danh tính (một cách dễ hiểu là M người khác nhau), mỗi danh tính chứa nhiều ảnh khuôn mặt khác nhau.

Trong quá trình huấn luyện, mô hình học ma trận đặc trưng trung tâm (feature center):

$$W \in \mathbb{R}^{M \times d}$$

trong đó mỗi hàng $W[j]$ là một vector đặc trưng trung tâm d chiều, với d là kích thước đặc trưng đã định nghĩa trước. Bên cạnh đó, mô hình sử dụng hàm mất mát **ArcFace** (Additive Angular Margin Loss [8]), là một dạng hàm cross-entropy được hiệu chỉnh như sau:

$$\mathcal{L}_{\text{ArcFace}}(\omega) = -\log \frac{e^{s \cos(\theta_i + m)}}{e^{s \cos(\theta_i + m)} + \sum_{j=1, j \neq i}^M e^{s \cos \theta_j}} \quad (6)$$


Trong đó:

$$\cos(\theta_j) = \frac{y^\top W[j]}{\|y\| \|W[j]\|}$$

với:

- θ_i là góc giữa đặc trưng y và tâm đặc trưng lớp $W[i]$,
- θ_j là góc giữa y và tâm đặc trưng lớp $W[j]$ ($j \neq i$),
- m là hệ số biên góc (angular margin),
- s là hệ số tỉ lệ (scaling factor).

Quy trình hoạt động của CryptoFace



Hình 1: Quy trình hoạt động của CryptoFace. Ảnh trên: offline; Ảnh dưới: online

Giai đoạn offline

Trong giai đoạn offline, Khách hàng gửi một ảnh tham chiếu $[x_1]$ đã mã hóa với khóa công khai (public key) cùng với danh tính tương ứng i đến máy chủ.

Máy chủ sử dụng mạng đã huấn luyện để trích xuất đặc trưng:

$$[y_1] = f_\omega([x_1])$$

và lưu trữ cặp:

$$(y_1, i)$$

Giai đoạn online

Trong giai đoạn xác thực, người dùng gửi ảnh đã mã hóa kiểm tra (probe) $[x_2]$ và danh tính khai báo i .

Máy chủ trích xuất đặc trưng:

$$[y_2] = f_w([x_2])$$

Sau đó, hàm $\text{Match}([y_1], [y_2])$ được gọi để tính toán kết quả. Kết quả so khớp đã mã hóa sẽ được gửi về cho khách hàng, và chỉ khách hàng mới có khóa riêng tư để giải mã kết quả.


Vậy, chỉ có khách hàng mới biết được kết quả rằng mình có **khớp** hay **không khớp**. Máy chủ hoàn toàn không có một chút thông tin về kết quả.

Mô hình đe dọa và bảo mật (Threat Model)

CryptoFace hoạt động dựa trên mô hình "**Bán trung thực**" (Semi-honest), nghĩa là cả khách hàng và máy chủ đều tuân thủ giao thức nhưng có thể cố gắng phân tích dữ liệu nhận được để lấy thêm thông tin.

- **Bảo vệ phía khách hàng:** Máy chủ chỉ nắm giữ hình ảnh và đặc trưng ở dạng mã hóa. Vì không có khóa bí mật của khách hàng, máy chủ không thể giải mã hoặc suy luận ra bất kỳ thông tin sinh trắc học nào từ dữ liệu khách hàng cung cấp.
- **Bảo vệ phía máy chủ:** Khách hàng không được tham gia vào quá trình trích xuất đặc trưng (vì việc này diễn ra hoàn toàn trên máy chủ). Khách hàng chỉ nhận được một kết quả duy nhất là một vector vô hướng (khớp/không khớp), do đó không thể suy luận ra các đặc trưng nhạy cảm đang được lưu trữ trong cơ sở dữ liệu của máy chủ.

3.3.2 CryptoFaceNet



Hình 2: Ảnh bên trái: Huấn luyện bản rõ (cleartext training); Ảnh bên phải: Suy luận trên dữ liệu mã hóa (encrypted inference)

Phương pháp chia patch

CryptoFaceNet lấy cảm hứng từ mô hình dựa trên patch: ảnh được chia thành các patch nhỏ, mỗi patch được xử lý bởi một PCNN nông, sau đó các đặc trưng cục bộ được hợp nhất thành đặc trưng toàn cục. Cách thiết kế này giảm độ trễ FHE nhờ độ sâu nhân thấp và khả năng đánh giá song song; huấn luyện bản rõ minh họa ở Hình 2 (trái).

Ký hiệu ảnh $\mathbf{x} \in \mathbb{R}^{C \times H \times W}$, ta chia thành các patch $\mathbf{x}_i \in \mathbb{R}^{C \times P \times P}$ với $i = 1, \dots, L$ và $L = \frac{HW}{P^2}$. Cách chia này theo tinh thần Vision Transformer (ViT) [9].

Hỗn hợp các PCNN (Mixture of PCNNs)

Hỗn hợp PCNN $\{f_{\omega_i}\}_{i=1}^L$ xử lý độc lập từng patch để tạo đặc trưng cục bộ $\mathbf{y}_i$, rồi hợp nhất thành đặc trưng toàn cục bằng:

$$\mathbf{y} = \mathbf{y}' \mathbf{A}^T + \mathbf{b}, \quad \mathbf{y}' = [\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_L], \quad (7)$$

với $\mathbf{A} \in \mathbb{R}^{d \times dL}$ và $\mathbf{b} \in \mathbb{R}^d$.

Vì $P \ll H, W$, mỗi patch có trường tiếp nhận nhỏ nên dùng PCNN nông, độ sâu nhân thấp. Các bộ lọc học riêng cho từng patch, giúp mô hình nắm quan hệ giữa các patch. Thiết kế này giảm độ trễ FHE nhờ tính song song, bảo toàn riêng tư trên dữ liệu mã hóa, và giữ được khả năng tính toán homomorphic.

Huấn luyện hỗn hợp PCNNs

Huấn luyện hỗn hợp PCNN dùng hàm mất mát ArcFace (Phương trình 6) và thêm nhiệm vụ phụ ghép hình jigsaw puzzle để bổ sung thông tin vị trí. Cụ thể, dùng các đặc trưng cục bộ $\mathbf{y}_1, \dots, \mathbf{y}_L$ dự đoán vị trí gốc (1..L) qua một lớp fully-connected, giúp đặc trưng mã hóa vị trí. Mục tiêu huấn luyện:

$$\mathcal{L}(\omega, \mathbf{W}, \mathbf{A}, \mathbf{b}) = \mathcal{L}_{\text{ArcFace}}(\omega, \mathbf{W}, \mathbf{A}, \mathbf{b}) + \alpha \mathcal{L}_{\text{Jigsaw}}(\omega), \quad (8)$$

trong đó $\omega = \{\omega_i\}_{i=1}^L$, $\mathbf{W}$ là trung tâm đặc trưng, $\mathbf{A}, \mathbf{b}$ là tham số hợp nhất, và α là hệ số của mất mát jigsaw. Thiết kế này kết hợp nhận diện chính xác với thông tin vị trí, giữ riêng tư khi suy luận trên dữ liệu mã hóa và tương thích tính toán homomorphic.

Khả năng suy luận

Suy luận được tăng tốc nhờ giảm độ sâu nhân (mỗi PCNN chỉ cần một bootstrapping) và đánh giá song song L PCNN (Hình 2, phải). Nút thắt là phép hợp nhất $\mathbf{y}' \mathbf{A}^T$ (Phương trình 7) cần nhiều phép quay homomorphic; vì $\mathbf{A} \in \mathbb{R}^{d \times dL}$ không phù hợp với nhân HE tối ưu cho ma trận vuông [11], ta tách $\mathbf{A}$ thành các khối vuông $\mathbf{A}_i$ để phân rã:

$$\mathbf{y} = \sum_{i=1}^L \left(\mathbf{y}_i \mathbf{A}_i^T + \frac{\mathbf{b}}{L} \right), \quad \text{trong đó } \mathbf{y}_i \in \mathbb{R}^d, \mathbf{A}_i \in \mathbb{R}^{d \times d}, \quad (9)$$


nơi các tích $\mathbf{y}_i \mathbf{A}_i^T + \frac{\mathbf{b}}{L}$ được đánh giá song song; dưới FHE, phép hợp nhất chỉ còn các phép cộng rẻ. Thiết kế này giảm số phép quay và vẫn giữ riêng tư trên dữ liệu mã hóa.

Khả năng mở rộng

Các HCNN hiện có (Section 3.2.2) khó mở rộng lên độ phân giải cao vì tăng kích thước tensor buộc tăng bậc N của vòng đa thức (Section 3.2.1), làm độ trễ tăng mạnh theo $O(\ell^2 N \log N)$ [13]. Ngược lại, hỗn hợp PCNN mà tác giả đề xuất có khả năng mở rộng tốt hơn, tăng số PCNN giúp tốc độ suy luận gần như độc lập với độ phân giải nhờ đánh giá song song.

3.3.3 Homomorphic Architecture

Kiến trúc Homomorphic của CryptoFaceNet được thiết kế nhằm hỗ trợ tính toán hiệu quả trên dữ liệu được mã hóa đồng hình đầy đủ, tập trung vào việc giảm độ sâu nhân và tối ưu hóa các phép toán tương thích với FHE trong khi vẫn đảm bảo khả năng trích xuất đặc trưng cho nhận diện khuôn mặt.



Hình 3: Các khối Convolutional và cài đặt FHE của nó. Left: ResNet; middle: AESPA; right: CryptoFaceNet.

Khối Convolutional. Nhóm tác giả áp dụng phép convolution FHE và hàm kích hoạt HerPN theo đa thức Hermite. Hình 3 minh họa khối AESPA [15] cùng triển khai FHE tương ứng. Độ sâu khối AESPA là 8 vì một convolution tiêu tốn 2 mức và một HerPN tiêu tốn 2 mức. Tác giả đề xuất khối AESPA dịch chuyển tối ưu độ sâu. Hình 3 cũng hiển thị các khối CryptoFaceNet cho $\text{stride} = 1$ và $\text{stride} = 2$.

Hàm HerPN có thể được biểu diễn như một đa thức bậc hai với độ sâu 2. Tác giả đã hợp nhất hệ số a vào trọng số convolution và thay đổi đa thức thành dạng có độ sâu 1. Do đó, khối CryptoFaceNet đề xuất có thể tiết kiệm hai mức.

$$\text{HerPN}(x) = ax^2 + bx + c \quad (10)$$

$$\text{HerPN}_{\text{proposed}}(x) = x^2 + \frac{b}{a}x + \frac{c}{a} \quad (11)$$

Thiết kế hợp nhất hệ số này nhằm tạo khối tối ưu độ sâu dưới FHE, lý do chọn phép toán hợp nhất hệ số a vào trọng số convolution là để giảm độ sâu của đa thức HerPN từ 2 xuống 1, mục tiêu bảo toàn tính riêng tư bằng cách thực hiện toàn bộ phép tính trong miền mã hóa homomorphic mà không cần giải mã trung gian, và cách đảm bảo khả năng tính toán trên dữ liệu mã hóa nhờ tiết kiệm đáng kể số mức tiêu thụ cho phép mạng có độ sâu lớn hơn mà vẫn chỉ yêu cầu bootstrapping tối thiểu.

Chuẩn hóa ℓ_2 theo Đa thức. Khi so sánh $\mathbf{y}_1, \mathbf{y}_2$, cần chuẩn hóa $\mathbf{y}/\|\mathbf{y}\|_2$ (Phương trình 5). Chuẩn hóa ℓ_2 có dạng sau, với $\mathbf{y} \in \mathbb{R}^d$:


$$\frac{\mathbf{y}}{\|\mathbf{y}\|_2} = \mathbf{y} \cdot \frac{1}{\sqrt{\sum_{i=1}^d y_i^2}} \quad (12)$$

Dưới FHE, $[y_i]^2$ dùng nhân ciphertext-ciphertext và tổng bằng phép quay. Khó nhất là xấp xỉ $q(t) = 1/\sqrt{t}$ với $t = \|\mathbf{y}\|_2^2$. Tác giả dùng đa thức bậc 2 dựa trên phân bố dữ liệu (3 điểm kiểm soát) để suy ra $\beta_2, \beta_1, \beta_0$, độ sâu nhân chỉ 2 nên hiệu quả, và ngưỡng T ở Phương trình 5 được ước lượng tương thích chuẩn hóa này.

$$p(t) = \beta_2 t^2 + \beta_1 t + \beta_0 \approx \frac{1}{\sqrt{t}} \quad (13)$$

Thiết kế này khắc phục hạn chế khi t có miền giá trị rộng, giữ hình dạng hàm với chi phí độ sâu thấp, bảo toàn riêng tư vì toàn bộ xấp xỉ diễn ra trên ciphertext, và đảm bảo tính toán hiệu quả nhờ độ sâu nhân tối thiểu.

Adaptive Average Pooling Tác giả dùng pooling trung bình thích ứng với đầu ra (2,2) thay vì (1,1) để giữ tốt hơn thông tin cấu trúc, tạo đặc trưng 256 chiều. Việc triển khai (2,2) được thực hiện bằng bốn phép pooling (1,1) (hoán vị các phần tử), nên ma trận hợp nhất $\mathbf{A}$ cũng được sắp xếp lại trong miền bản rõ. Thiết kế này cân bằng giữa chất lượng đặc trưng và chi phí tính toán, đồng thời tương thích với các phép toán homomorphic trong pipeline FHE.



Hình 4: Kiến trúc CryptoFaceNet. Top: training; bottom: inference.

Kiến trúc CryptoFaceNet. Kiến trúc được minh họa ở Hình 4. Để giảm độ sâu, CryptoFaceNet

hợp nhất Linear và BatchNorm1D thành một lớp Linear, tổng hợp đặc trưng bằng phép cộng ciphertext đơn giản, và chỉ cần một lần bootstrapping. Thiết kế này giảm độ sâu, đơn giản hóa suy luận FHE, và giữ được tính riêng tư với độ trễ thấp.

3.3.4 Mục tiêu kỹ thuật, Phương pháp tiếp cận và Tính hiệu quả

Từ những nội dung nêu ở trên, có thể thấy hệ thống **CryptoFace** được thiết kế để giải quyết bài toán nhận dạng khuôn mặt bảo mật với các khía cạnh cụ thể sau:

- **Mục tiêu kỹ thuật:** Mục tiêu cốt lõi là xây dựng một quy trình nhận dạng khuôn mặt mã hóa đầu-cuối hoàn chỉnh. Hệ thống hướng tới việc bảo vệ dữ liệu sinh trắc học nhạy cảm của người dùng trong suốt ba giai đoạn: trích xuất đặc trưng, lưu trữ và so khớp. Điều này đảm bảo rằng máy chủ có thể thực hiện nhiệm vụ xác thực mà không bao giờ tiếp cận được ảnh thô hoặc đặc trưng chưa mã hóa, đồng thời cung cấp khả năng bảo mật hậu mã hóa lượng tử thông qua FHE.
- **Phương pháp tiếp cận:** Hệ thống sử dụng kiến trúc **CryptoFaceNet**, thay thế các mạng nơ-ron sâu truyền thống bằng *hỗn hợp các PCNNs*. Ảnh khuôn mặt được chia thành L mảnh nhỏ, mỗi mảnh được xử lý độc lập bởi một mạng PCNN nông. Phương pháp này kết hợp các kỹ thuật tối ưu:
 1. **Đánh giá song song:** Tận dụng đặc tính của FHE để xử lý đồng thời tất cả các mạng PCNN.
 2. **Xấp xỉ đa thức:** Sử dụng đa thức bậc thấp dựa trên phân phối dữ liệu để thực hiện các phép toán phi tuyến như chuẩn hóa L_2 và tính điểm tương đồng Cosine.
 3. **Tối ưu hóa độ sâu:** Hợp nhất các lớp (như Conv và hệ số đa thức) để giảm thiểu độ sâu nhân (multiplicative depth).
- **Tính hiệu quả của phương pháp:** Phương pháp này đạt hiệu quả cao nhờ việc giải quyết triệt để "nút thắt cổ chai" về tốc độ của FHE. Bằng cách giảm độ sâu của mạng, CryptoFace hạn chế tối đa các thao tác *bootstrapping* tốn kém. Bên cạnh đó, thiết kế dựa trên mảnh ảnh giúp độ trễ suy luận gần như không phụ thuộc vào độ phân giải, cho phép hệ thống mở rộng lên ảnh độ phân giải cao mà vẫn duy trì tốc độ nhanh.

3.4 Dữ liệu và thực nghiệm

Để vượt qua rào cản tốc độ tính toán chậm chạp của FHE, nghiên cứu tập trung thiết kế kiến trúc mạng **CryptoFaceNet** sử dụng hỗn hợp các mạng CNN cục bộ, phân mảnh (patch-based) nhằm giảm độ sâu phép nhân, qua đó tăng tốc độ suy luận và hỗ trợ xử lý ảnh ở độ phân giải cao.

Bài báo sử dụng tổng cộng 8 bộ dữ liệu, được chia thành 3 nhóm chính: 1 bộ dữ liệu dùng để huấn luyện, 5 bộ dữ liệu kiểm thử tiêu chuẩn, và 2 bộ dữ liệu kiểm thử độ khó cao.

3.4.1 Bộ dữ liệu Huấn luyện

- **Tên bộ dữ liệu:** WebFace4M (là một tập con của WebFace260M).
- **Thông tin tổng quan:** Là bộ dữ liệu nhận dạng khuôn mặt quy mô lớn được sử dụng làm tiêu chuẩn để dạy cho các mô hình AI cách trích xuất đặc trưng khuôn mặt.
- **Trong thí nghiệm của bài báo:**
 - **Mục tiêu:** Dùng để huấn luyện mạng CryptoFace và các mạng cơ sở (baselines) trên dữ liệu thô bằng framework PyTorch.
 - **Cấu trúc:** Bộ dữ liệu chứa tổng cộng 205.990 danh tính (identities) với 4.235.242 hình ảnh khuôn mặt.
 - **Yêu cầu huấn luyện:** Ảnh đầu vào được cắt thành các mảnh (patch) có kích thước 32×32 . Mô hình được huấn luyện kết hợp hàm mất mát ArcFace và Jigsaw. Các siêu tham số gồm: learning rate 0.05 (giảm dần ở các epoch 12, 20, 24), 26 epochs, batch size 256, momentum 0.9, weight decay 0.0005, thuật toán tối ưu SGD và cắt gradient (gradient clipping) ở mức 1.

3.4.2 Các bộ dữ liệu kiểm thử chuẩn

- **Tên các bộ dữ liệu:** LFW, AgeDB, CALFW, CPLFW, CFP-FP.
- **Thông tin tổng quan:** Đây là 5 bộ dữ liệu đánh giá nhận dạng khuôn mặt tiêu chuẩn, bao gồm các hình ảnh chất lượng cao để kiểm tra tính chính xác của thuật toán.
- **Trong thí nghiệm của bài báo:**
 - **Mục tiêu chính:** Đánh giá độ chính xác của bài toán xác thực 1:1 (one-to-one verification accuracy) trên các hình ảnh đã bị mã hóa FHE.
 - **Mục tiêu phụ:** Riêng bộ LFW còn được trích ngẫu nhiên một tập con 128 cặp để chạy thử nghiệm bài toán định danh (1:128 closed-set rank retrieval).
 - **Cấu trúc:** Bộ CFP-FP chứa 7.000 cặp ảnh (tương đương 14.000 ảnh). Bốn bộ còn lại (LFW, AgeDB, CALFW, CPLFW) mỗi bộ chứa 6.000 cặp ảnh (tương đương 12.000 ảnh).
 - **Kích thước đầu vào:** Độ phân giải gốc là 112×112 . Tác giả đã resize ảnh thành ba mức: nhỏ (64×64), trung bình (96×96) và lớn (128×128) để mô phỏng các môi trường ứng dụng thực tế (thiết bị biên, nhúng, và đám mây).
 - **Đặc điểm kiểm thử:** Áp dụng phương pháp xác thực chéo 10 lần (10-fold cross-validation). Ở mỗi vòng, 9 nhóm dữ liệu dạng thô được dùng để ước lượng ngưỡng và phương trình xấp xỉ đa thức, còn 1 nhóm (đã mã hóa thành ciphertext) dùng để kiểm tra hiệu suất.

3.4.3 Các bộ dữ liệu kiểm thử chất lượng hỗn hợp

- **Tên các bộ dữ liệu:** IJB-B và IJB-C.
- **Thông tin tổng quan:** Chứa các hình ảnh khuôn mặt có chất lượng pha trộn (từ rõ đến mờ nhòe, che khuất), được thiết kế chuyên biệt để thử thách giới hạn của các mô hình nhận dạng.
- **Trong thí nghiệm của bài báo:**
 - **Mục tiêu:** Đo lường hiệu suất của hệ thống CryptoFace trước những tình huống khó khăn trong môi trường mã hóa thông qua đường cong ROC và chỉ số AUC.
 - **Cấu trúc & Đặc điểm xử lý:** Do chi phí tính toán trên bản mã FHE là cực kỳ lớn (prohibitively high computational cost), tác giả không đánh giá toàn bộ tập dữ liệu mà chỉ lấy mẫu ngẫu nhiên **1.200 cặp** từ mỗi bộ (trong đó có 50% cặp dương tính - cùng người, và 50% cặp âm tính - khác người) để tiến hành chạy kiểm thử.

3.4.4 Môi trường phần cứng và phần mềm cho thực nghiệm

Tác giả đã chỉ định rõ ràng các môi trường được sử dụng cho cả hai giai đoạn huấn luyện (trên dữ liệu thô) và suy luận (trên dữ liệu mã hóa):

- **Môi trường phần mềm:**
 - Quá trình huấn luyện mô hình trên dữ liệu thô được thực hiện bằng framework **PyTorch**.
 - Quá trình suy luận trên FHE được lập trình bằng **C++**, xây dựng dựa trên thư viện **SEAL** (Microsoft SEAL) đã được tinh chỉnh để hỗ trợ thao tác Bootstrapping (kế thừa từ MPCNN và AutoFHE).
- **Môi trường phần cứng:** Để đánh giá khách quan về độ trễ (latency) và mức tiêu thụ RAM của quá trình nhận dạng mã hóa, tác giả đã triển khai chạy thực nghiệm trên máy chủ đám mây **Amazon AWS r5.24xlarge**.

3.4.5 Thiết lập huấn luyện và Siêu tham số

Nghiên cứu áp dụng trực tiếp các thiết lập huấn luyện từ mạng **AdaFace** mà không cần phải tinh chỉnh thêm cho môi trường dữ liệu thô.

- **Siêu tham số huấn luyện mạng (trên Cleartext):**
 - Epochs: 26.
 - Batch size: 256.
 - Optimizer: **SGD** kết hợp với bộ lập lịch đa bước (multi-step scheduler).

- Learning rate: Khởi tạo ở mức 0.05 và được giảm đi 10 lần ($0.1\times$) tại các epoch thứ 12, 20 và 24.
- Momentum: 0.9.
- Weight decay: 0.0005.
- Patch size: 32×32 .
- **Thiết lập mật mã FHE:** Để đảm bảo an toàn mật mã ở mức **128-bit security**, tác giả sử dụng hệ thống mật mã CKKS với bậc của vành đa thức (cyclotomic ring degree) là 2^{16} , Hamming weight là 192, module mặc định là 46 bits và module đặc biệt là 51 bits.

3.4.6 Các kỹ thuật đặc biệt

Để giúp mạng nơ-ron hoạt động ổn định và chính xác khi chuyển đổi sang môi trường mã hóa FHE, tác giả đã sử dụng các kỹ thuật sau:

- **Gradient Clipping:** Trong quá trình huấn luyện CryptoFace (và cả mạng AutoFHE), tác giả thực hiện kỹ thuật cắt gradient nhằm chống lại hiện tượng bùng nổ gradient thường gặp khi huấn luyện các mạng sử dụng hàm kích hoạt đa thức.
- **Tác vụ phụ "Xếp hình":** Thay vì dùng các kỹ thuật tăng cường dữ liệu truyền thống, tác giả áp dụng một nhiệm vụ học tăng cường. Vì khuôn mặt bị cắt thành nhiều mảnh nhỏ, hàm mất mát Jigsaw (với cường độ $\alpha = 0.005$) được thêm vào hàm mất mát ArcFace chính để ép mô hình phải học cách dự đoán vị trí ban đầu của các mảnh ảnh, qua đó bảo tồn được thông tin vị trí của khuôn mặt.
- **Xấp xỉ Chuẩn hóa L2 theo phân phối dữ liệu:** Đây là một kỹ thuật toán học đặc biệt được sử dụng để thay thế hàm căn bậc hai (vốn không tính được trên FHE) bằng một phương trình đa thức bậc hai có đồ thị bám sát sự phân phối của dữ liệu huấn luyện.

3.5 Kết quả và thảo luận

3.5.1 Kết quả chính

Hệ thống **CryptoFace** đạt được những cải tiến vượt trội so với các phương pháp mã hóa đồng hình tiên tiến nhất trên các bộ dữ liệu chuẩn như LFW, AgeDB, và CPLFW:

- **Tốc độ xử lý:** CryptoFace tăng tốc độ suy luận lên gấp **7 lần** so với MPCNN. Cụ thể, thời gian thực hiện nhận diện trên miền mã hóa giảm từ 9.845 giây xuống còn **1.364 giây** cho ảnh độ phân giải 64×64 .
- **Độ phân giải và Độ trễ:** Nhờ kiến trúc mạng tích chập mảnh (PCNN) song song, hệ thống duy trì độ trễ gần như không đổi (từ **1.364s** đến **1.446s**) ngay cả khi tăng độ phân giải từ 64×64 lên 128×128 .

- **Độ chính xác xác thực:** So với kiến trúc AutoFHE, CryptoFace cải thiện độ chính xác xác thực trung bình thêm **+6,73%**. Khi sử dụng ảnh độ phân giải cao (128×128), hệ thống đạt độ chính xác trung bình là **91,46%**.
- **Hiệu quả tài nguyên:** Giảm mức chiếm dụng bộ nhớ RAM khoảng **17GB** so với các phương pháp cơ sở do chỉ yêu cầu tối thiểu một thao tác bootstrapping duy nhất.

Phương pháp	Độ chính xác TB (%)	Độ trễ (Giây)	RAM (GB)
MPCNN (ResNet44)	89,64	9.845	286
AutoFHE (ResNet32)	82,69	4.001	286
CryptoFace	89,42	1.364	269

Bảng 3: So sánh hiệu năng giữa CryptoFace và các phương pháp FHE khác (Độ phân giải 64×64)

3.5.2 Điểm mạnh

Phương pháp **CryptoFace** mang lại những đóng góp quan trọng trong lĩnh vực nhận dạng khuôn mặt bảo mật nhờ các ưu điểm kỹ thuật sau:

- **Bảo mật đầu-cuối thực thụ:** Khác với các hệ thống trước đây chỉ mã hóa đặc trưng khuôn mặt, CryptoFace là hệ thống đầu tiên thực hiện toàn bộ quy trình từ trích xuất đặc trưng, lưu trữ đến so khớp hoàn toàn trong miền mã hóa FHE. Điều này loại bỏ nguy cơ lộ ảnh thô hoặc đặc trưng sinh trắc học tại bất kỳ giai đoạn nào.
- **Kiến trúc CryptoFaceNet tối ưu độ sâu:** Bằng cách sử dụng hỗn hợp PCNNs, hệ thống giảm thiểu đáng kể độ sâu nhân. Điều này giúp hạn chế tối đa các thao tác *bootstrapping* tốn kém, vốn là rào cản chính về tốc độ trong các mạng nơ-ron mã hóa đồng hình (FHENets).
- **Khả năng mở rộng độ phân giải:** Nhờ cơ chế xử lý song song các mảnh ảnh ($P \times P$), CryptoFace duy trì thời gian xử lý gần như không đổi ngay cả khi tăng độ phân giải hình ảnh từ 64×64 lên 128×128 . Đây là một bước đột phá so với các kiến trúc truyền thống vốn có độ trễ tăng vọt khi kích thước đầu vào tăng lên.
- **Chuẩn hóa L_2 và so khớp hiệu quả:** Nhóm tác giả đề xuất hàm xấp xỉ đa thức bậc thấp dựa trên phân phối dữ liệu để thực hiện chuẩn hóa L_2 và tính khoảng cách Cosine. Kỹ thuật này chỉ tiêu tốn khoảng 0,02% tổng thời gian suy luận nhưng vẫn đảm bảo độ chính xác cao.
- **Bảo toàn cấu trúc thông qua Jigsaw Task:** Việc kết hợp nhiệm vụ phụ trợ giải đố Jigsaw trong quá trình huấn luyện giúp các mạng PCNN nông học được mối quan hệ không gian giữa các mảnh ảnh, từ đó duy trì khả năng nhận diện mạnh mẽ tương đương với các mạng nơ-ron sâu trong miền giải mã.

3.5.3 Khả năng ứng dụng của kiến trúc

Kiến trúc **CryptoFace** mở ra triển vọng triển khai nhận dạng khuôn mặt trong các môi trường yêu cầu bảo mật cao và quyền riêng tư tuyệt đối:

- **Tài chính và eKYC:** Cho phép xác thực danh tính khách hàng và phê duyệt giao dịch mà không làm lộ dữ liệu sinh trắc học gốc, giúp ngăn chặn triệt để nguy cơ đánh cắp danh tính.
- **Chính phủ điện tử:** Ứng dụng trong kiểm soát biên giới và quản lý danh tính quốc gia, đảm bảo tuân thủ các quy định khắt khe như GDPR nhờ khả năng lưu trữ và đối soát trên miền mã hóa.
- **Dịch vụ đám mây bảo mật (FRaaS):** Cung cấp dịch vụ nhận diện khuôn mặt trên đám mây dưới dạng dịch vụ mà không cần tin tưởng vào nhà cung cấp hạ tầng, vì dữ liệu luôn được giữ ở trạng thái mã hóa.
- **Y tế và Doanh nghiệp:** Quản lý truy cập hồ sơ bệnh án hoặc khu vực nhạy cảm, bảo vệ quyền riêng tư hình ảnh của bệnh nhân và nhân viên theo các tiêu chuẩn quốc tế.

3.5.4 Hạn chế và thách thức

1. Chi phí tính toán và độ trễ hệ thống Dù CryptoFace đã cải thiện tốc độ gấp 7 lần so với các hệ thống FHE tiên tiến nhất như MPCNN, thời gian suy luận vẫn là một thách thức lớn đối với các ứng dụng thời gian thực.

- Hệ thống mạng lớn nhất (CryptoFaceNet16) khi xử lý hình ảnh độ phân giải 128×128 vẫn cần tới khoảng 1.446 giây (xấp xỉ 24 phút) cho một lần suy luận trực tuyến.
- Độ trễ này khiến hệ thống chưa thể đáp ứng các kịch bản cần phản hồi lập tức như mở khóa thiết bị di động, mà phù hợp hơn cho các tác vụ kiểm tra an ninh thụ động hoặc các hệ thống yêu cầu bảo mật tuyệt đối hơn là tốc độ.

2. Yêu cầu phần cứng cao (RAM Footprint) Các hệ thống sử dụng lược đồ CKKS của mã hóa đồng cấu toàn phần nổi tiếng với việc tiêu tốn tài nguyên bộ nhớ cực lớn.

- Mặc dù đã tối ưu hóa để giảm số lượng thao tác bootstrapping xuống còn 1 lần, giúp tiết kiệm khoảng 17GB so với các phương pháp trước đó, bộ nhớ RAM tối thiểu cần thiết để vận hành máy chủ vẫn dao động từ 269 GB đến 277 GB.
- Điều này đòi hỏi hạ tầng máy chủ cấu hình rất cao (như Amazon AWS r5.24xlarge), gây khó khăn cho việc triển khai rộng rãi ở quy mô doanh nghiệp nhỏ.

3. Sai số do xấp xỉ đa thức

Phép xấp xỉ này phụ thuộc chặt chẽ vào phân phối dữ liệu huấn luyện. Nếu dữ liệu đầu vào thực tế có sự sai lệch lớn về phân phối, độ chính xác của phép chuẩn hóa sẽ giảm sút, buộc hệ thống phải liên tục ước tính lại ngưỡng so khớp T .

4. Giới hạn của Fixed-Point Lược đồ CKKS hỗ trợ tính toán số học xấp xỉ, điều này có nghĩa là kết quả trả về không hoàn hảo tuyệt đối về mặt bit (vấn đề của not bit-perfect).

- Việc tích lũy sai số qua các lớp mạng nơ-ron sâu có thể làm sai lệch kết quả nhận diện ở quy mô dữ liệu khổng lồ.
- Hệ thống đòi hỏi việc quản lý mức nhiễu và các tham số mô-đun một cách cực kỳ tinh vi để tránh thất bại trong quá trình giải mã.

5. Giả định về Threat Model CryptoFace hiện tại được thiết kế dựa trên mô hình thực thể "bán trung thực" (semi-honest).

- **Thách thức:** Mô hình này chưa tính đến các đối thủ "thâm độc" (malicious) cố tình gửi bản mã sai định dạng để thăm dò cấu trúc mô hình.
- Hệ thống cũng chưa giải quyết triệt để các rủi ro từ tấn công kênh bên (side-channel attacks) tiềm ẩn trên máy chủ khi thực hiện các phép toán FHE cường độ cao.

6. Giới hạn không gian mẫu Do giới hạn về quy mô nghiên cứu, khả năng bao phủ không gian mẫu (sampling space coverage) chưa được đánh giá chi tiết trên mọi biến thể ngoại cảnh thực tế. Đây vẫn là một hướng mở cho các nghiên cứu tương lai nhằm cải thiện khả năng tổng quát hóa của hệ thống.

3.5.5 Kết luận

Bài báo CryptoFace cho thấy việc xây dựng hệ thống nhận diện khuôn mặt mã hóa hoàn toàn (end-to-end encrypted) là khả thi mà vẫn giữ được độ chính xác cao. Điểm quan trọng là mô hình không chỉ áp dụng mã hóa như một lớp bảo vệ bên ngoài, mà được thiết kế lại để phù hợp với tính toán trên dữ liệu mã hóa. Điều này giúp cân bằng giữa bảo mật và hiệu năng, đồng thời đảm bảo dữ liệu khuôn mặt không bao giờ bị lộ ở dạng thô.

Tuy nhiên, để áp dụng được CryptoFace và chạy thực nghiệm trong thực tế thì còn yêu cầu hạ tầng lớn. Để có thể chạy được thực nghiệm, chúng tôi cần phải đào sâu vào một phần nhỏ hơn của mô hình, đó chính là CipherFace.

4 CipherFace - Một framework nhẹ hơn

4.1 Vấn đề của nhóm

Trong quá trình cố gắng chạy thực nghiệm với CryptoFace, nhóm nhận ra rằng phần cứng, và các nền tảng cloud free không đủ lớn để nhóm chạy thực nghiệm cho toàn bộ pipeline FHE của CryptoFace. Vậy nên, sau khi cân nhắc và nhận sự gợi ý của thầy **Võ Thành Lâm**, nhóm đã quyết định đọc thêm một paper **CipherFace: A Fully Homomorphic Encryption-Driven Framework for Secure Cloud-Based Facial Recognition** [16] được đăng công khai vào tháng 22/02/2025. Tác giả của bài báo này cũng chính là tác giả của một Framework rất nổi tiếng trong bài toán nhận diện khuôn mặt **DeepFace**.

4.2 Phương pháp đề xuất

4.2.1 Mục tiêu chung với CryptoFace

Cả *CipherFace* và *CryptoFace* đều chia sẻ mục tiêu cốt lõi là bảo vệ tính riêng tư của dữ liệu sinh trắc học thông qua mã hóa đồng hình (FHE), cho phép thực hiện các phép toán trực tiếp trên bản mã mà không cần giải mã dữ liệu.

Trong mỗi liên hệ phát triển, *CipherFace* đóng vai trò là tiền đề kỹ thuật quan trọng, tiên phong trong việc thiết lập các phương pháp luận về tính toán khoảng cách tương đồng (Euclidean và Cosine) an toàn cho các vector đặc trưng (*embeddings*) trên môi trường điện toán đám mây.

Kế thừa các tư tưởng về xử lý trong miền mã hóa từ công trình này, *CryptoFace* đã mở rộng và tối ưu hóa các kỹ thuật đó để xây dựng một hệ thống đầu-cuối (*End-to-End*) hoàn thiện, thực hiện bảo mật xuyên suốt từ hình ảnh thô tại phía Client cho đến khâu đối soát tại Server.

Sự chuyển tiếp này khẳng định *CipherFace* chính là nền tảng lý thuyết và kỹ thuật, cung cấp các giải pháp tính toán khoảng cách mã hóa mà *CryptoFace* đã kế thừa và phát triển để đạt được mức độ bảo mật toàn diện hơn.

4.2.2 Ý tưởng giải pháp

Ý tưởng cốt lõi của *CipherFace* là thiết lập một kiến trúc phối hợp lai (*Hybrid Architecture*), tối ưu hóa sự cân bằng giữa tính bảo mật sinh trắc học và hiệu suất thực thi trên môi trường đám mây. Thay vì mã hóa toàn bộ quy trình từ ảnh thô, vốn gây áp lực tính toán cực lớn cho hệ thống mã hóa đồng hình, giải pháp tập trung bảo vệ các vector đặc trưng (*embeddings*) ngay sau khi chúng được trích xuất.

Trình tự ý tưởng giải pháp được triển khai theo các giai đoạn logic sau:

- **Phân định vai trò thực thi:** Quy trình nhận diện được chia làm hai phần. Phía *On-premises* (Client) đảm nhiệm các tác vụ nặng về xử lý ảnh (phát hiện, căn chỉnh và trích xuất đặc

trung) và quản lý khóa bí mật. Phía *Cloud* (Server) chỉ nhận các bản mã để thực hiện các phép so khớp tương đồng.

- **Tương thích hóa toán học cho FHE:** Do mã hóa đồng hình hoàn toàn chỉ hỗ trợ hiệu quả các phép cộng và nhân, *CipherFace* đề xuất ý tưởng biến đổi các công thức khoảng cách phi tuyến thành dạng đại số tuyến tính cơ bản.
- **Cơ chế tiền xử lý:** Để xử lý khoảng cách *Euclidean* và *Cosine*, ý tưởng chủ đạo là thực hiện các bước chuẩn hóa (l_2 và *Min-Max normalization*) tại phía Client trước khi mã hóa. Điều này cho phép loại bỏ phép chia và khai căn trong miền mã hóa, chuyển đổi bài toán về các phép tính tích vô hướng (*dot product*) đơn giản trên Cloud.
- **Quy trình xác thực hai bước:** Cloud tính toán kết quả khoảng cách dưới dạng bản mã và gửi trả lại. Việc giải mã và so sánh với ngưỡng (*threshold*) chỉ được thực hiện tại phía Client, đảm bảo Server hoàn toàn không thể tiếp cận dữ liệu gốc hay kết quả định danh cuối cùng.

Cách tiếp cận này cung cấp một framework linh hoạt, cho phép tích hợp các mô hình Deep Learning hiện đại vào một lớp bảo mật FHE ổn định. Đây chính là nền tảng phương pháp luận mà *CryptoFace* đã kế thừa để nâng cấp thành một hệ thống đầu-cuối toàn diện hơn.

4.2.3 Chi tiết giải pháp

Giải pháp *CipherFace* được hiện thực hóa thông qua việc kết hợp thư viện *DeepFace* để trích xuất đặc trưng và *TenSEAL* để thực hiện các phép toán mã hóa đồng hình hoàn toàn. Quy trình kỹ thuật chi tiết được triển khai như sau:

1. Biến đổi công thức tính khoảng cách Euclidean Do FHE không hỗ trợ phép khai căn trực tiếp, *CipherFace* thực hiện tính toán bình phương khoảng cách Euclidean trên Cloud.

- **Tại Server (Cloud):** Thực hiện phép trừ và tính tích vô hướng của hiệu hai vector để thu được bình phương khoảng cách đã mã hóa:

$$[d(\alpha, \beta)^2] = \sum_{i=1}^n ([\alpha_i] - [\beta_i])^2 \quad (14)$$

- **Tại Client (On-premises):** Sau khi nhận kết quả giải mã $d(\alpha, \beta)^2$, hệ thống sẽ so sánh với bình phương của ngưỡng xác thực (T^2) để đưa ra kết luận.

2. Tối ưu hóa tính toán khoảng cách Cosine Khoảng cách Cosine đối mặt với hai rào cản: phép chia để tính Norm và các giá trị âm gây lỗi tỷ lệ (*scale*) trong FHE. Giải pháp được thực hiện qua các bước:

- **Tiền xử lý tại Client:** Thực hiện chuẩn hóa vector ($\hat{\alpha}, \hat{\beta}$) và chuẩn hóa Min-Max để đảm bảo các giá trị đầu vào đều dương trước khi mã hóa:

$$\hat{\alpha} = \frac{\alpha}{\|\alpha\|}, \quad \hat{\beta} = \frac{\beta}{\|\beta\|} \quad (15)$$

- **Tính toán tại Cloud:** Cloud thực hiện tích vô hướng giữa hai bản mã để thu được độ tương đồng Cosine. Để chuyển sang giá trị khoảng cách, Cloud tạo một bản mã của giá trị "1" và thực hiện phép trừ đồng hình:

$$[\theta(\alpha, \beta)] = [1] - [\hat{\alpha} \cdot \hat{\beta}] \quad (16)$$

$$[\theta(\alpha, \beta)] = [1] - \left[\frac{\alpha}{\|\alpha\|} \cdot \frac{\beta}{\|\beta\|} \right] \quad (17)$$

3. Mô tả hệ thống thuật toán Quy trình vận hành của *CipherFace* được chuẩn hóa qua ba thuật toán chính:

- **Thuật toán 1 (Khởi tạo):** Thực hiện tại phía người dùng. Ảnh khuôn mặt được trích xuất thành embeddings, chuẩn hóa (nếu dùng Cosine), mã hóa bằng khóa công khai và lưu trữ lên Cloud.
- **Thuật toán 2 (So khớp mã hóa):** Thực hiện tại Cloud. Khi có yêu cầu nhận diện, Server nhận bản mã của ảnh truy vấn, thực hiện tính toán bình phương khoảng cách Euclidean hoặc khoảng cách Cosine trên miền mã hóa và trả kết quả về Client.
- **Thuật toán 3 (Xác thực):** Thực hiện tại phía người dùng. Client sử dụng khóa bí mật để giải mã kết quả và thực hiện so sánh ngưỡng cuối cùng để xác định danh tính.

Việc chuyển đổi các phép toán phi tuyến thành các phép tính đại số đơn giản thông qua chuẩn hóa dữ liệu chính là chìa khóa giúp *CipherFace* vượt qua giới hạn của FHE, tạo tiền đề để *CryptoFace* kế thừa và tích hợp sâu các hàm xấp xỉ đa thức vào kiến trúc mạng nơ-ron sau này.

4.2.4 Tại sao lại làm như vậy

Việc lựa chọn phương pháp triển khai của *CipherFace* xuất phát từ những yêu cầu cấp bách về tính bảo mật sinh trắc học và khả năng vận hành thực tế của hệ thống:

- **Giải quyết mâu thuẫn giữa bảo mật và hiệu suất đám mây:** Dữ liệu sinh trắc học là bất biến, nếu bị lộ sẽ gây ra hậu quả vĩnh viễn. Phương pháp này cho phép tận dụng sức mạnh tính toán của Cloud để xử lý các truy vấn lớn mà vẫn đảm bảo dữ liệu luôn ở trạng thái mã hóa, bảo vệ quyền riêng tư tuyệt đối cho người dùng.

- **Vượt qua giới hạn vật lý của FHE:** Các "workaround" như tính bình phương khoảng cách và chuẩn hóa tại Client là bắt buộc vì hệ thống FHE không hỗ trợ phép chia hoặc khai căn trực tiếp. Những điều chỉnh này giúp duy trì độ chính xác của thuật toán nhận diện trong khi vẫn tương thích với các giới hạn của lý thuyết mật mã.
- **Tính khả thi về mặt thực nghiệm:** Việc chỉ tập trung mã hóa lớp *embeddings* giúp hệ thống duy trì độ trễ thấp. Thực tế cho thấy cấu hình FHE tiêu chuẩn chỉ làm tăng từ 2,4% đến 3,7% tổng thời gian xử lý, đây là một con số không đáng kể so với thời gian trích xuất đặc trưng của mô hình Deep Learning.

Hệ quả nếu không áp dụng giải pháp Nếu sử dụng các phương pháp truyền thống, hệ thống sẽ đối mặt với các rủi ro nghiêm trọng:

- **Nguy cơ từ mã hóa đối xứng (AES):** Để tính toán khoảng cách, máy chủ Cloud buộc phải giải mã dữ liệu, dẫn đến rủi ro lộ khóa bí mật hoặc rò rỉ dữ liệu ngay tại bộ nhớ máy chủ.
- **Hạn chế về khả năng mở rộng:** Nếu thực hiện toàn bộ quy trình tại thiết bị Client nhằm giữ an toàn, hệ thống sẽ gặp nghẽn cổ chai về tài nguyên khi cơ sở dữ liệu khôn mặt tăng lên, đồng thời không tận dụng được năng lực xử lý song song của các trung tâm dữ liệu.

Việc thiết lập các cơ chế tính toán khoảng cách mã hóa của *CipherFace* không chỉ giải quyết bài toán hiện tại mà còn tạo ra lộ trình kỹ thuật để các công trình sau này như *CryptoFace* phát triển lên mức độ bảo mật đầu-cuối toàn diện hơn.

4.3 Dữ liệu và thực nghiệm

4.3.1 Dữ liệu thực nghiệm

Tác giả bài báo đã thực nghiệm trên tập dữ liệu *Labeled Faces in the Wild (LFW)*. LFW là một bộ dữ liệu tiêu chuẩn được sử dụng trong bài toán nhận dạng và xác minh khuôn mặt trong điều kiện thực tế. Dataset này bao gồm hơn 13,000 ảnh khuôn mặt của hơn 5,000 người, được thu thập từ các nguồn trên internet với sự đa dạng lớn về góc nhìn, ánh sáng, biểu cảm và chất lượng ảnh. Mỗi người có thể có nhiều ảnh, và các ảnh không được chuẩn hóa hoàn toàn, khiến bài toán trở nên gần với thực tế hơn so với các dataset trong phòng thí nghiệm.

4.3.2 Môi trường phần cứng và phần mềm

Để đánh giá hiệu năng của hệ thống, tác giả bài báo đã thiết lập môi trường thực nghiệm mô phỏng sự phối hợp giữa nền tảng Windows và Linux thông qua WSL 2.

Cấu hình phần cứng Thực nghiệm được triển khai trên hệ thống máy tính có các thông số kỹ thuật chi tiết như sau:

- **Bộ vi xử lý (CPU):** 11th Generation Intel(R) Core(TM) i7-11370H @ 3.30 GHz (4 cores, 8 threads), hỗ trợ ảo hóa VT-x.
- **Kiến trúc:** x86-64.
- **Bộ nhớ (RAM):** 15 GB RAM vật lý và 4 GB không gian hoán đổi (*swap space*).
- **Lưu trữ:** 953 GB tổng dung lượng đĩa cứng.

Môi trường phần mềm Các công cụ và thư viện được sử dụng bao gồm:

- **Hệ điều hành:** Linux chạy trên môi trường *Windows Subsystem for Linux* (WSL 2), sử dụng phiên bản nhân 5.15.167.4-microsoft-standard-WS.
- **Thư viện xử lý khuôn mặt:** *DeepFace* (Python) đóng vai trò trích xuất các vector đặc trưng (*embeddings*).
- **Thư viện mật mã:** *TenSEAL* được sử dụng để thực thi các phép toán trên miền mã hóa đồng hình hoàn toàn (FHE).

4.3.3 Thiết lập thực nghiệm và Siêu tham số

Tác giả đã tiến hành thực nghiệm để kiểm chứng khả năng mở rộng của *CipherFace* đối với các kích thước *embedding* và cấu hình mật mã khác nhau.

Tham số dữ liệu và mô hình

- **Tập dữ liệu:** Tập kiểm tra của LFW bao gồm 1.000 cặp ảnh (500 cặp cùng danh tính và 500 cặp khác danh tính).
- **Mô hình và Kích thước Embedding:**
 - FaceNet128d (128 chiều).
 - FaceNet512d (512 chiều).
 - VGG-Face (4.096 chiều).
- **Phép đo khoảng cách:** Euclidean và Cosine.

Cấu hình Mật mã học (FHE Parameters) Hệ thống được thiết lập để đảm bảo độ bảo mật 128-bit (an toàn vượt qua năm 2030) với hai cấu hình chính:

- **Cấu hình nhỏ (Small):** Bậc đa thức $n = 2^{13}$, kích thước modulus $q = 200$ bits, tỷ lệ toàn cục $g = 2^{40}$.
- **Cấu hình lớn (Large):** Bậc đa thức $n = 2^{14}$, kích thước modulus $q = 422$ bits, tỷ lệ toàn cục $g = 2^{60}$.

Ngưỡng xác thực (Thresholds) Các ngưỡng xác thực được sử dụng đúng theo các cài đặt tinh chỉnh sẵn (*pre-tuned*) của mô hình:

- **FaceNet512:** Euclidean: 24.35; Cosine: 0.0287.
- **FaceNet:** Euclidean: 12.28; Cosine: 0.0243.
- **VGG-Face:** Euclidean: 1.17; Cosine: 0.6639.

4.3.4 Thư viện mã hóa

Trong nghiên cứu này, tác giả sử dụng thư viện Microsoft SEAL để triển khai mã hóa đồng hình, cho phép thực hiện các phép toán trực tiếp trên dữ liệu đã mã hóa mà không cần giải mã, từ đó đảm bảo tính riêng tư.

Hai cấu hình hệ mật được sử dụng nhằm đánh giá sự đánh đổi giữa hiệu năng và độ bảo mật:

- **Cấu hình nhỏ:** $n = 2^{13}$, $q = 200$, $g = 40$
- **Cấu hình lớn:** $n = 2^{14}$, $q = 422$, $g = 60$

Trong đó:

- n (*polynomial modulus degree*): bậc của đa thức mô-đun, quyết định kích thước không gian tính toán và ảnh hưởng trực tiếp đến cả độ bảo mật lẫn chi phí tính toán. Giá trị n càng lớn thì mức độ bảo mật càng cao nhưng thời gian xử lý cũng tăng.
- q (*coefficient modulus*): tổng số bit của mô-đun hệ số, ảnh hưởng đến độ chính xác số học và độ sâu của các phép toán đồng cấu có thể thực hiện. Giá trị q lớn hơn cho phép thực hiện nhiều phép toán hơn trước khi bị nhiễu, nhưng làm tăng chi phí tính toán.
- g (*global scale*): hệ số tỷ lệ toàn cục được sử dụng trong lược đồ CKKS để biểu diễn số thực. Giá trị g kiểm soát độ chính xác của các phép tính trên dữ liệu mã hóa, giá trị càng lớn thì độ chính xác càng cao nhưng cũng làm tăng tiêu tốn tài nguyên.

Cả hai cấu hình đều đạt mức bảo mật 128-bit theo hướng dẫn của thư viện SEAL, đảm bảo an toàn trước các tấn công hiện đại và được xem là đủ mạnh để sử dụng lâu dài.

4.4 Kết quả thực nghiệm từ bài báo gốc

4.4.1 Kết quả chính

Các thí nghiệm đánh giá hệ thống CipherFace trong bài báo gốc được tiến hành trên tập dữ liệu Labeled Faces in the Wild (LFW) với 1.000 cặp hình ảnh. Nhóm tác giả đã đánh giá hiệu năng dựa trên hai cấu hình mật mã (cấu hình nhỏ và cấu hình lớn), sử dụng hai độ đo khoảng cách (Euclidean và Cosine) trên ba kích thước vector đặc trưng khác nhau bao gồm FaceNet-128d, FaceNet-512d và VGG-Face.

Việc áp dụng mã hóa đồng hình tất yếu tạo ra độ trễ do các thao tác mã hóa, tính toán đồng hình và giải mã. Tuy nhiên, kết quả thực nghiệm cho thấy các thao tác này chỉ diễn ra trong vài mili-giây, minh chứng cho tính khả thi của hệ thống. Cụ thể, đối với mô hình FaceNet-128d ở cấu hình mật mã nhỏ, tổng thời gian xử lý chỉ tăng thêm 2,4% so với quy trình không mã hóa thông thường (từ 1590,75 ms/it lên 1628,82 ms/it). Ngược lại, khi áp dụng cấu hình bảo mật lớn hơn nhằm gia tăng độ an toàn, chi phí thời gian (overhead) tăng lên một cách rõ rệt: gia tăng 18% đối với FaceNet-128d, 17,6% đối với FaceNet-512d và lên tới 37% đối với mô hình VGG-Face có số chiều lớn. Chi tiết về thời gian xử lý trên từng cấu hình và mô hình được tóm tắt trong Bảng 4 dưới đây.

Bảng 4: Kết quả thực nghiệm nhận dạng khuôn mặt trên miền mã hóa của bài báo gốc CipherFace

n	q	g	Distance	Operation	Performance (ms / it)		
					FaceNet (128d)	FaceNet (512d)	VGG-Face (4096d)
2^{13}	200	2^{40}	Euclidean	Encryption	7.19	7.40	7.56
				Homomorphic	29.18	34.56	42.66
				Decryption	1.85	1.97	1.99
2^{13}	200	2^{40}	Cosine	Encryption	7.72	8.34	8.06
				Homomorphic	29.36	35.27	43.88
				Decryption	1.99	2.15	1.88
2^{14}	422	2^{60}	Euclidean	Encryption	25.63	24.14	26.13
				Homomorphic	239.81	278.55	392.16
				Decryption	15.21	14.12	16.30
2^{14}	422	2^{60}	Cosine	Encryption	24.39	24.10	24.47
				Homomorphic	236.64	308.64	347.22
				Decryption	13.11	12.95	13.75

4.4.2 Điểm mạnh

Một trong những đóng góp nổi bật nhất của CipherFace là việc đề xuất phương pháp tính toán khoảng cách mới trên dữ liệu mã hóa, giải quyết thành công những hạn chế cố hữu của mã hóa đồng hình toàn phần. Thay vì phải thực hiện phép tính căn bậc hai (một thao tác phức tạp và

không được hỗ trợ trực tiếp trong FHE) hệ thống tính toán bình phương khoảng cách Euclidean trên đám mây và so sánh nó với bình phương của ngưỡng định sẵn ở máy cục bộ. Tương tự, đối với khoảng cách Cosine, việc xử lý các giá trị âm hoặc phép chia cho độ lớn vector rất dễ gây ra lỗi tràn vi. Để khắc phục, hệ thống thực hiện chuẩn hóa min-max và chia vector cho độ lớn của chính nó ngay tại máy cục bộ trước khi mã hóa và đẩy lên đám mây.

Về mặt an toàn, hệ thống áp dụng các cấu hình cung cấp mức bảo mật 128-bit theo khuyến nghị của thư viện SEAL, được đánh giá là an toàn và đủ sức chống chịu các rủi ro dài hạn, ít nhất là qua năm 2030. Kiến trúc phân tán này cho phép tận dụng tối đa sức mạnh tính toán của đám mây để so sánh các bản mã mà không yêu cầu khách hàng phải chia sẻ khóa bí mật, đảm bảo quyền riêng tư tuyệt đối.

Đặc biệt, để nâng cao tính thực tiễn, nhóm tác giả đã công bố mã nguồn mở (open-sourced) bằng ngôn ngữ Python trên nền tảng GitHub. Nhờ việc sử dụng các thư viện phổ biến và mạnh mẽ như DeepFace (để trích xuất đặc trưng) và TenSEAL (để tính toán FHE), CipherFace dễ dàng được các nhà phát triển và cộng đồng nghiên cứu tích hợp, kiểm chứng và ứng dụng vào các kịch bản thực tế thay vì chỉ dừng lại ở lý thuyết.

4.4.3 Khả năng ứng dụng của kiến trúc

Kiến trúc của CipherFace được thiết kế một cách tối ưu nhằm phục vụ cho các hệ thống nhận diện khuôn mặt dựa trên nền tảng đám mây, đặc biệt là trong các tình huống đòi hỏi tính riêng tư dữ liệu nghiêm ngặt. Đáng chú ý, tính ứng dụng của mô hình này không bị giới hạn trong lĩnh vực sinh trắc học khuôn mặt. Do bản chất cốt lõi của hệ thống là khả năng so khớp các vector nhúng (embeddings) ở dạng mã hóa, CipherFace hoàn toàn có thể được nhân rộng cho mọi bài toán tìm kiếm độ tương tự (similarity search).

Một số ứng dụng tiềm năng khác của hệ thống bao gồm: so sánh tài liệu một cách bảo mật để phát hiện hành vi đạo văn, xây dựng hệ thống gợi ý cá nhân hóa trên các nền tảng thương mại điện tử mà không thu thập dữ liệu thô, phân tích hồ sơ y tế cho mục đích chẩn đoán lâm sàng, và phát hiện gian lận trong các mạng lưới giao dịch tài chính. Hơn thế nữa, khả năng mở rộng linh hoạt theo kích thước cơ sở dữ liệu và chiều dài của vector đặc trưng chứng tỏ đây là một giải pháp thiết thực cho môi trường triển khai thực tế quy mô lớn.

4.4.4 Hạn chế và thách thức

Dù mang lại những cải tiến đáng kể về mặt bảo mật, CipherFace vẫn còn tồn đọng một số hạn chế nội tại. Bản chất của Mã hóa đồng hình hoàn toàn (FHE) là một kỹ thuật tiêu tốn rất nhiều tài nguyên, yêu cầu sử dụng các kích thước khóa lớn hơn gấp nhiều lần so với mã hóa đối xứng thông thường và tạo ra chi phí tính toán cao. Hạn chế này bộc lộ rõ nhất khi hệ thống áp dụng các cấu hình bảo mật mạnh hơn hoặc sử dụng những mô hình biểu diễn đặc trưng có số chiều quá lớn (chẳng hạn như VGG-Face với 4096 chiều), dẫn đến sự gia tăng độ trễ một cách đáng kể ở bước trích xuất đặc trưng.

Thêm vào đó, việc thực thi các phép tính toán đồng hình đối với độ đo khoảng cách Cosine có phần đòi hỏi nhiều tài nguyên điện toán hơn so với khoảng cách Euclidean. Cuối cùng, do mô hình chỉ thực hiện mã hóa ở mức đặc trưng thay vì đầu-cuối như CryptoFace, quá trình trích xuất đặc trưng - vốn là bước tốn kém nhất trong đường ống nhận diện - vẫn buộc phải diễn ra tại thiết bị máy khách (Client/Edge) trước khi mã hóa. Điều này tạo ra rào cản ứng dụng đối với những thiết bị đầu cuối có năng lực điện toán và phần cứng hạn hẹp.

5 Thực nghiệm của nhóm với CipherFace

5.1 Dữ liệu thực nghiệm

5.1.1 Labeled Faces in the Wild

Nhóm tái thực nghiệm bài toán trên bộ dữ liệu LFW đã sử dụng trong bài báo nhằm kiểm chứng và so sánh các kết quả.

5.1.2 Tập dữ liệu mở rộng: Pins Face Recognition (PFR)

Để mở rộng và đa dạng thực nghiệm hơn, ngoài tập LFW mang tính chuẩn mực, nhóm đã chủ động chạy bài toán trên một tập dữ liệu không được đề cập trong bài báo gốc là *Pins Face Recognition (PFR)* [4].

Tập dữ liệu PFR bao gồm tổng cộng 17.534 hình ảnh khuôn mặt của 105 nhân vật nổi tiếng. Việc nhóm quyết định tích hợp thêm PFR vào quy trình thực nghiệm không chỉ để làm phong phú dữ liệu, mà còn xuất phát từ những luận điểm mang tính phê bình đối với các nghiên cứu hiện tại:

- **Khắc phục giới hạn không gian mẫu:** Như đã phân tích ở các hệ thống tiền nhiệm, một trong những điểm yếu lớn nhất của các mô hình FHE hiện tại là chưa đánh giá chi tiết trên mọi biến thể ngoại cảnh thực tế. Trong khi LFW thường chỉ chứa các hình ảnh với góc mặt khá trực diện, PFR mang lại độ phức tạp cao hơn hẳn nhờ sự biến thiên lớn về góc độ gương mặt, điều kiện chiếu sáng, tư thế và các biểu cảm đa dạng (thu thập tự nhiên từ Pinterest).
- **Tạo bài Stress test cho các phép toán FHE:** Bài báo gốc CipherFace chỉ thực nghiệm trên một mẫu rất nhỏ của LFW (1.000 cặp ảnh). Khi hình ảnh đầu vào đa dạng và có độ nhiễu cao như PFR, các vector đặc trưng sinh ra sẽ có độ phân tán cực lớn. Việc dùng PFR giúp nhóm kiểm chứng xem các kỹ thuật tiền xử lý của CipherFace (như chuẩn hóa Min-Max và chuẩn hóa L_2 tại máy cục bộ) có còn giữ được sự ổn định và độ chính xác khi thực hiện tính toán khoảng cách Cosine/Euclidean trên miền mã hóa hay không.
- **Đánh giá độ bền bỉ trong kịch bản định danh mật độ cao:** Tập PFR có mật độ dữ liệu rất dày (trung bình hơn 167 ảnh cho mỗi danh tính). Việc phân loại trên một tập dữ liệu có độ nén cao như vậy cho phép nhóm đánh giá chính xác khả năng tổng quát hóa (*generalization*)

và độ bền bỉ (*robustness*) của đường ống nhận diện, chứng minh tính khả thi của hệ thống CipherFace khi triển khai vào các mạng lưới xã hội thực tế thay vì chỉ trong môi trường phòng thí nghiệm.

5.2 Cấu hình thực nghiệm

5.2.1 Phần cứng

Ở đây, nhóm chạy thực nghiệm trên CPU của Kaggle với cấu hình phần cứng như sau:

- **Model name:** Intel(R) Xeon(R) CPU @ 2.20GHz
- **Kiến trúc:** x86_64 (Intel/AMD server-grade)
- **CPU MHz:** 2200
- **RAM:** 30GB
- **HDD:** 57.6GB

5.2.2 Siêu tham số

Các siêu tham số và nhóm dùng đúng y như các cài đặt của tác giả.

- **Random Seed:** 42
- **Model:** Facenet512, Facenet, VGG-Face
- **Distance Metrics:** Euclidean, Cosine
- **Threshold (Facenet512):**
 - Euclidean: 24.35
 - Cosine: 0.028744931705153496
- **Threshold (Facenet):**
 - Euclidean: 12.28
 - Cosine: 0.02431508799003538
- **Threshold (VGG-Face):**
 - Euclidean: 1.17
 - Cosine: 0.663973458216446

5.2.3 Thư viện mã hóa

Phần này nhóm thực hiện nhất quán với bài báo.

- **Cấu hình nhỏ:** $n = 2^{13}$, $q = 200$, $g = 40$
- **Cấu hình lớn:** $n = 2^{14}$, $q = 422$, $g = 60$

Trong đó:

- n (*polynomial modulus degree*) là bậc của đa thức mô-đun, quyết định kích thước không gian tính toán và ảnh hưởng trực tiếp đến cả độ bảo mật lẫn chi phí tính toán. Giá trị n càng lớn thì mức độ bảo mật càng cao nhưng thời gian xử lý cũng tăng.
- q (*coefficient modulus*) là tổng số bit của mô-đun hệ số, ảnh hưởng đến độ chính xác số học và độ sâu của các phép toán đồng cấu có thể thực hiện. Giá trị q lớn hơn cho phép thực hiện nhiều phép toán hơn trước khi bị nhiễu, nhưng làm tăng chi phí tính toán.
- g (*global scale*) là hệ số tỷ lệ toàn cục được sử dụng trong lược đồ CKKS để biểu diễn số thực. Giá trị g kiểm soát độ chính xác của các phép tính trên dữ liệu mã hóa; giá trị càng lớn thì độ chính xác càng cao nhưng cũng làm tăng tiêu tốn tài nguyên.

Cả hai cấu hình đều đạt mức bảo mật 128-bit theo hướng dẫn của thư viện SEAL, đảm bảo an toàn trước các tấn công hiện đại và được xem là đủ mạnh để sử dụng lâu dài.

5.3 Kết quả thực nghiệm của nhóm

5.3.1 Tập LFW

Bảng 5: Thực nghiệm của nhóm trên tập LFW với số liệu đánh giá 'performance' (ms/it)

n	q	g	Distance	Operation	Performance (ms / it)					
					FaceNet (128d)		FaceNet (512d)		VGG-Face (4096d)	
					Paper	Nhóm	Paper	Nhóm	Paper	Nhóm
2 ¹³	200	2 ⁴⁰	Euclidean	Encryption	7.19	11.35	7.40	11.79	7.56	8.50
				Homomorphic	29.18	29.64	34.56	36.14	42.66	29.41
				Decryption	1.85	1.99	1.97	2.06	1.99	1.44
2 ¹³	200	2 ⁴⁰	Cosine	Encryption	7.72	12.17	8.34	10.91	8.06	13.09
				Homomorphic	29.36	32.52	35.27	32.94	43.88	45.67
				Decryption	1.99	2.20	2.15	1.88	1.88	2.23
2 ¹⁴	422	2 ⁶⁰	Euclidean	Encryption	25.63	35.97	24.14	42.39	26.13	37.49
				Homomorphic	239.81	235.71	278.55	319.38	392.16	358.47
				Decryption	15.21	13.99	14.12	15.81	16.30	14.25
2 ¹⁴	422	2 ⁶⁰	Cosine	Encryption	24.39	23.37	24.10	24.13	24.47	36.49
				Homomorphic	236.64	153.14	308.64	184.87	347.22	354.32
				Decryption	13.11	9.21	12.95	9.42	13.75	14.34

Chú thích:

- **In đậm:** Các chỉ số tốt nhất của Nhóm.
- **In nghiêng:** Các chỉ số tốt nhất của Tác Giả.

Bảng 6: So sánh kết quả thực nghiệm trên LFW: Accuracy, Precision, Recall, F1-score và AUC

n	q	g	Distance	FaceNet (128d)						FaceNet (512d)						VGG-Face																	
				Acc		Pre		Rec		F1		AUC		Acc		Pre		Rec		F1		AUC											
				P	N	P	N	P	N	P	N	P	N	P	N	P	N	P	N	P	N	P	N										
2 ¹³	200	2 ⁴⁰	Euclidean	-	0.96	-	0.99	-	0.92	-	0.96	-	0.99	-	0.97	-	0.99	-	0.94	-	0.96	-	1.00	-	0.95	-	0.96	-	0.92	-	0.94	-	0.99
2 ¹³	200	2 ⁴⁰	Cosine	-	0.95	-	1.00	-	0.88	-	0.93	-	0.99	-	0.97	-	0.96	-	0.98	-	0.97	-	1.00	-	0.95	-	0.98	-	0.91	-	0.94	-	0.99
2 ¹⁴	422	2 ⁶⁰	Euclidean	-	0.96	-	0.99	-	0.92	-	0.96	-	0.99	-	0.97	-	0.99	-	0.94	-	0.96	-	1.00	-	0.95	-	0.96	-	0.93	-	0.94	-	0.99
2 ¹⁴	422	2 ⁶⁰	Cosine	-	0.92	-	1.00	-	0.84	-	0.91	-	0.99	-	0.94	-	1.00	-	0.89	-	0.94	-	1.00	-	0.95	-	0.98	-	0.91	-	0.94	-	0.99

* Ghi chú: P = Paper, N = Nhóm (Dữ liệu do nhóm tự diễn)

Phân tích và nhận xét kết quả thực nghiệm

Dựa trên các bảng số liệu so sánh giữa kết quả thực nghiệm của nhóm và bài báo gốc (Cipherface), nhóm đưa ra các phân tích và lý giải về sự khác biệt như sau:

1. Phân tích về hiệu năng tính toán (Performance) Nhìn chung, thời gian thực thi của nhóm có sự chênh lệch so với *Paper*, cụ thể:

- **Thao tác Mã hóa (Encryption):** Kết quả của nhóm thường cao hơn *Paper* từ 30% đến 50% (ví dụ: FaceNet-128d ở cấu hình $n = 2^{13}$ đạt 11.35 ms/it so với 7.19 ms/it của tác giả). Điều này lý giải do sự khác biệt về xung nhịp CPU: Intel Xeon trên Kaggle (2.20GHz) có tốc độ xử lý đơn nhân thấp hơn so với Intel i7-11370H (3.30GHz) được sử dụng trong bài báo.
- **Thao tác Đồng hình (Homomorphic):** Đây là điểm đáng chú ý khi trong một số trường hợp, nhóm đạt tốc độ nhanh hơn *Paper* (ví dụ: FaceNet-128d Cosine $n = 2^{14}$ đạt 153.14 ms/it so với 236.64 ms/it). Sự cải thiện này có thể do thư viện *TenSEAL* đã tối ưu hóa khả năng tính toán song song tốt hơn trên kiến trúc nhiều nhân của CPU Xeon cấp độ máy chủ so với dòng CPU di động của i7.
- **Độ phức tạp theo tham số mật mã:** Cả hai kết quả đều cho thấy sự tăng vọt về thời gian khi nâng cấp từ $n = 2^{13}$ lên $n = 2^{14}$ (tăng gấp 8-10 lần). Điều này hoàn toàn khớp với lý thuyết về mật mã học đồng hình, khi kích thước đa thức n và modulus q lớn hơn làm tăng khối lượng tính toán theo hàm $\mathcal{O}(N \log N)$.

2. Phân tích về Độ chính xác và các chỉ số chất lượng Các chỉ số định lượng về khả năng nhận diện của nhóm cho thấy tính ổn định cao:

- **Độ chính xác:** Nhóm đạt mức dao động từ 0.92 đến 0.97 trên các mô hình khác nhau. Kết quả này tương đồng với các công bố của *CipherFace* về việc FHE không làm suy giảm độ chính xác của mô hình gốc, do quá trình mã hóa đồng hình bảo toàn các giá trị tính toán so với miền số thực.
- **Sự ổn định của AUC:** Chỉ số AUC đạt mức 0.99 một cách nhất quán trên tất cả các cấu hình. Điều này khẳng định rằng mặc dù thời gian tính toán có thể thay đổi tùy thuộc vào phần cứng, nhưng khả năng phân biệt (*discriminative power*) của hệ thống giữa các cặp ảnh cùng danh tính và khác danh tính vẫn được duy trì ở mức xuất sắc.

Chú ý: Tác giả không cung cấp các số liệu như Accuracy, Precision, Recall, F1-Score, AUC trong paper của tác giả. Việc đánh giá thêm các số liệu này chính là ý định của nhóm, nhằm kiểm tra độ hiệu quả của DeepFace.

3. Lý giải sự khác biệt Sự khác biệt về số liệu chủ yếu xuất phát từ môi trường thực thi:

- **Kiến trúc phần cứng:** Xung nhịp CPU (GHz) ảnh hưởng trực tiếp đến tốc độ mã hóa/giải mã, trong khi số lượng luồng (*threads*) và bộ nhớ đệm (*cache*) của CPU Xeon máy chủ hỗ trợ tốt hơn cho các phép toán tensor đồng hình phức tạp.

- **Môi trường ảo hóa:** Việc chạy trên Kaggle (môi trường ảo hóa/container) có thể dẫn đến sự biến động nhẹ về I/O so với chạy trực tiếp trên WSL2 của hệ điều hành máy chủ như trong *Paper*.

Kết luận: Thực nghiệm của nhóm đã tái lập thành công các kết quả cốt lõi của bài báo *CipherFace*. Sự sai lệch về thời gian nằm trong ngưỡng cho phép của sự khác biệt phần cứng và không làm ảnh hưởng đến độ tin cậy cũng như tính bảo mật của toàn bộ hệ thống.

5.3.2 Tập PFR

Bảng 7: Thực nghiệm của nhóm trên tập PFR với số liệu đánh giá 'performance' (ms/it)

n	q	g	Distance	Operation	Performance (ms / it)					
					FaceNet (128d)		FaceNet (512d)		VGG-Face (4096d)	
					Paper	Nhóm	Paper	Nhóm	Paper	Nhóm
2^{13}	200	2^{40}	Euclidean	Encryption	-	11.40	-	11.06	-	8.04
				Homomorphic	-	29.46	-	34.03	-	27.92
				Decryption	-	1.94	-	1.93	-	1.36
2^{13}	200	2^{40}	Cosine	Encryption	-	11.26	-	7.96	-	11.23
				Homomorphic	-	29.55	-	22.99	-	40.19
				Decryption	-	2.00	-	1.37	-	1.88
2^{14}	422	2^{60}	Euclidean	Encryption	-	36.00	-	37.87	-	38.72
				Homomorphic	-	229.31	-	285.72	-	360.92
				Decryption	-	13.95	-	14.38	-	14.47
2^{14}	422	2^{60}	Cosine	Encryption	-	24.41	-	23.97	-	39.36
				Homomorphic	-	149.66	-	179.35	-	375.66
				Decryption	-	9.61	-	9.61	-	14.75

Bảng 8: So sánh kết quả thực nghiệm trên PFR: Accuracy, Precision, Recall, F1-score và AUC

n	q	g	Distance	FaceNet (128d)						FaceNet (512d)						VGG-Face																	
				Acc		Pre	Rec	F1	AUC	Acc		Pre	Rec	F1	AUC	Acc		Pre	Rec	F1	AUC												
				P	N	P	N	P	N	P	N	P	N	P	N	P	N	P	N	P	N												
2 ¹³	200	2 ⁴⁰	Euclidean	-	0.88	-	0.99	-	0.77	-	0.86	-	0.98	-	0.90	-	0.99	-	0.79	-	0.88	-	0.98	-	0.90	-	0.97	-	0.82	-	0.89	-	0.97
2 ¹³	200	2 ⁴⁰	Cosine	-	0.78	-	1.00	-	0.57	-	0.72	-	0.98	-	0.91	-	0.99	-	0.82	-	0.90	-	0.99	-	0.91	-	0.96	-	0.85	-	0.90	-	0.97
2 ¹⁴	422	2 ⁶⁰	Euclidean	-	0.88	-	0.99	-	0.77	-	0.86	-	0.98	-	0.90	-	0.99	-	0.79	-	0.88	-	0.98	-	0.88	-	0.96	-	0.80	-	0.87	-	0.97
2 ¹⁴	422	2 ⁶⁰	Cosine	-	0.65	-	1.00	-	0.30	-	0.47	-	0.98	-	0.79	-	1.00	-	0.59	-	0.74	-	0.99	-	0.91	-	0.96	-	0.85	-	0.90	-	0.97

* Ghi chú: P = Paper, N = Nhóm (Dữ liệu của nhóm)

Phân tích và nhận xét kết quả thực nghiệm

Việc áp dụng hệ thống CipherFace lên tập dữ liệu Pins Face Recognition (PFR), một dataset không được tác giả bài báo gốc triển khai, đã cung cấp một góc nhìn phản biện sâu sắc về giới hạn thực

tế của hệ thống. Dựa trên Bảng 7 và Bảng 8, chúng em tiến hành đối chiếu và lý giải các độ lệch kết quả so với bài báo gốc như sau:

1. Mức độ chênh lệch kết quả

Sự chênh lệch giữa thực nghiệm của nhóm trên PFR và công bố của tác giả trên LFW được thể hiện rõ qua hai khía cạnh:

- **Về hiệu năng thời gian - bảng 7:** Thời gian thực thi của nhóm có sự biến động trái chiều so với Bảng 4 của bài báo gốc. Cụ thể, thao tác Mã hóa (Encryption) của nhóm chạy chậm hơn. Ví dụ: ở cấu hình FaceNet-128d (Euclidean, $n = 214$), thời gian mã hóa của nhóm là 36.00 ms/it, chậm hơn đáng kể so với 25.63 ms/it của tác giả. Tuy nhiên, ở khâu Tính toán đồng hình (Homomorphic), nhóm lại đạt tốc độ nhanh hơn ở một số cấu hình (ví dụ: FaceNet-128d Cosine $n = 214$ nhóm chỉ mất 149.66 ms/it so với 236.64 ms/it của tác giả).
- **Về chất lượng nhận diện - bảng 8:** Đây là nơi xảy ra sự chênh lệch và phân hóa cực đoan nhất. Ở cấu hình FaceNet-128d (Cosine, $n = 214$), Độ chính xác giảm chỉ còn 0.65. Đáng báo động hơn là khoảng cách giữa hai chỉ số: trong khi **Precision đạt mức gần tuyệt đối 1.00**, thì **Recall chỉ ở mức 0.30**, kéo theo F1-score chỉ còn 0.47. Dù vậy, tồn tại một vài nghịch lý: **AUC vẫn duy trì cao ở mức 0.98** (trên FaceNet-128d) và 0.97 - 0.99 ở các cấu hình khác.

2. Lý giải nguyên nhân của sự chênh lệch

Sự khác biệt về kết quả hoàn toàn không phải do lỗi ngẫu nhiên, mà bắt nguồn từ rào cản phần cứng, bản chất dữ liệu và cấu hình.


- **Khác biệt về Phần cứng:** Việc khâu mã hóa của nhóm chậm hơn xuất phát thuần túy từ xung nhịp CPU. Tác giả chạy trên vi xử lý Intel Core i7-11370H (3.30 GHz), trong khi nhóm thực nghiệm trên môi trường máy chủ Kaggle dùng Intel Xeon (chỉ 2.20 GHz). Xung nhịp đơn nhân thấp hơn đã kéo dài thời gian mã hóa. Ngược lại, tốc độ tính toán đồng hình đôi lúc nhanh hơn có thể nhờ thư viện TenSEAL tận dụng tốt hơn khả năng xử lý đa luồng trên cấu trúc CPU máy chủ của Kaggle.
- **Khác biệt về Dữ liệu:** Tập PFR được thu thập từ Pinterest với độ phức tạp cao hơn hẳn LFW về góc độ, ánh sáng và tư thế. Điều này khiến khoảng cách nội lớp giữa các ảnh của cùng một người bị phân tán và nới rộng ra rất nhiều so với LFW.
- **Hội chứng quá khớp ngưỡng:** Sự đối lập cực đoan giữa Precision (1.00) và Recall (0.30) là điểm yếu của bài báo gốc. Tác giả đã cố định các **ngưỡng khoảng cách tính** được tinh chỉnh quá khắt khe cho tập LFW (ví dụ: ngưỡng Cosine cho FaceNet-128d là 0.0243). Khi áp dụng ngưỡng này sang tập PFR, hệ thống lầm tưởng các khoảng cách bị nới rộng (do nhiễu ảnh) là của người lạ, dẫn đến việc **từ chối hàng loạt các cặp ảnh đúng**. Tuy nhiên, vì ngưỡng quá nghiêm ngặt, hệ thống kết luận là "khớp" thì chắc chắn cặp đó là đúng (**Precision giữ vững 1.00**).

- **Chỉ số AUC:** Việc AUC vẫn đạt mức 0.98 chứng tỏ rằng bản thân thuật toán mã hóa đồng hình tính toán khoảng cách hoàn toàn chuẩn xác và mạng DeepFace vẫn phân tách cực kỳ tốt ranh giới giữa người quen - người lạ. Từ đó cho thấy, FHE hoạt động vẫn tốt, lỗi nằm ở việc hệ thống đối chiếu kết quả với một cái ngưỡng cấu hình tĩnh không còn phù hợp.

Kết luận: Thực nghiệm mở rộng trên PFR khẳng định rằng: để áp dụng nhận dạng khuôn mặt FHE vào các kịch bản thực tế, việc sử dụng các thiết lập tĩnh như tác giả bài báo gốc là không khả thi. Hệ thống cần các thuật toán ước lượng ngưỡng động linh hoạt theo từng độ phân tán của dữ liệu nhiều.

6 Cải tiến của nhóm trên FaceNet128d

6.1 FaceNet128d



Hình 5: Kiến trúc FaceNet128d (được vẽ bởi Gemini)

6.1.1 Mô tả kiến trúc cơ sở

Kiến trúc *FaceNet128d_V1* được thiết kế như một mạng nơ-ron tích chập chuyên biệt để trích xuất đặc trưng khuôn mặt thành một vector đặc trưng. Quá trình xử lý luồng dữ liệu của mạng có thể được chia thành các thành phần chính như sau:

- **Mạng cơ sở (Backbone):** Mô hình sử dụng kiến trúc *Inception-ResNet-v1* đã được huấn luyện trước trên bộ dữ liệu quy mô lớn *VGGFace2*. Tầng phân loại cuối cùng của mạng gốc được loại bỏ (**classify=False**), đóng vai trò như một bộ trích xuất đặc trưng để tạo ra vector đặc trưng toàn cục với số chiều là 512.

- **Embedding Layer** Nhằm đáp ứng yêu cầu tối ưu hóa không gian biểu diễn, một tầng biến đổi tuyến tính (`nn.Linear`) được áp dụng để chiếu vector đặc trưng từ không gian $\mathbb{R}^{512}$ xuống không gian embedding $\mathbb{R}^{128}$.
- **Hàm kích hoạt Regularization:** Đầu ra của tầng nhúng được đưa qua hàm kích hoạt phi tuyến *ReLU* để tăng cường khả năng biểu diễn. Sau đó, kỹ thuật *Dropout* với xác suất $p = 0.3$ được áp dụng để vô hiệu hóa ngẫu nhiên một phần nơ-ron, giúp ngăn chặn hiện tượng quá khớp trong quá trình huấn luyện.
- **Classifier:** Đối với tác vụ huấn luyện hiện tại (ví dụ: trên tập dữ liệu LFW), một tầng kết nối đầy đủ (`nn.Linear`) cuối cùng được sử dụng để ánh xạ từ vector nhúng 128 chiều sang các giá trị *logits* tương ứng với số lượng lớp cần phân loại.

6.1.2 Hạn chế của kiến trúc hiện tại

Dù đáp ứng được yêu cầu thu gọn kích thước mô hình thông qua việc nén vector đặc trưng, kiến trúc cơ sở này vẫn bộc lộ những hạn chế về mặt bảo toàn và khai thác thông tin:

- **Tổn thất thông tin không gian và kênh:** Việc nén trực tiếp thông qua một phép chiếu tuyến tính (Linear mapping) từ 512 xuống 128 chiều dễ dẫn đến việc đánh mất nhiều thông tin không gian (spatial) và thông tin ngữ nghĩa (channel) phức tạp vốn đã được mạng *Inception-ResNet-v1* trích xuất ở các tầng chập sâu.
- **Thiếu cơ chế chất lọc cục bộ:** Trong mạng cơ sở hiện tại, mọi vùng không gian ảnh và mọi kênh đặc trưng đều được gán mức độ quan trọng xấp xỉ nhau trước khi bị gộp lại (pooling). Điều này khiến mô hình gặp khó khăn trong việc phân biệt đâu là các đặc điểm nhận diện cốt lõi (như mắt, mũi, miệng) và đâu là vùng nhiễu (phông nền, tóc, các phần bị che khuất).

6.1.3 Đề xuất hướng cải tiến: Tích hợp Module CBAM Attention


Để khắc phục bài toán suy giảm thông tin do quá trình nén và thiếu hụt khả năng tập trung cục bộ, kiến trúc cần được bổ sung một cơ chế "học cách chú ý" ngay tại mức bản đồ đặc trưng (feature maps) trước khi thực hiện bước giảm chiều.

Đây là cơ sở để kiến trúc cải tiến đề xuất tích hợp **Convolutional Block Attention Module (CBAM)**. CBAM sẽ hoạt động như một bộ lọc thông tin kép được tinh chỉnh tự động trong quá trình huấn luyện:

1. **Channel Attention:** Giúp mạng xác định "*đặc trưng nào là quan trọng?*" bằng cách gán trọng số lớn hơn cho các kênh (filters) biểu diễn các đặc điểm hữu ích nhất của khuôn mặt.
2. **Chú Spatial Attention:** Hỗ trợ mạng xác định "*vị trí nào là quan trọng?*" bằng cách khuếch đại tín hiệu tại các tọa độ mang tính phân biệt cao, đồng thời triệt tiêu nhiễu từ bối cảnh xung quanh.

Bằng cách nhúng CBAM vào các khối cuối của mạng backbone (trước tầng biến đổi tuyến tính), các feature map sẽ được tinh chế mạnh mẽ hơn. Nhờ đó, vector đặc trưng $\mathbb{R}^{512}$ thu được sẽ giàu tính phân biệt, đảm bảo rằng khi bị ép xuống không gian $\mathbb{R}^{128}$, vector nhúng này vẫn mang theo những các thông tin quan trọng nhất, từ đó cải thiện độ chính xác và tính bền vững của toàn bộ hệ thống nhận dạng.

6.2 FaceNet128d cải tiến sử dụng CBAM Attention



Hình 6: Kiến trúc FaceNet128d sử dụng CBAM Attention (được vẽ bởi Gemini)

6.2.1 Động lực cải tiến

Như đã phân tích ở phần trước, việc nén trực tiếp vector đặc trưng toàn cục trong cấu trúc FaceNet128d cơ sở dẫn đến sự hao hụt nghiêm trọng về thông tin không gian và kênh. Nhằm khắc phục triệt để vấn đề này, kiến trúc đề xuất *FaceNet128d_Attention_V2* được thiết kế để can thiệp sâu hơn vào luồng dữ liệu của mạng cơ sở. Giải pháp cốt lõi là tích hợp module **CBAM** (Convolutional Block Attention Module [17]) nhằm đánh trọng số và chất lọc các feature maps ngay *trước* khi chúng bị gộp mất thông tin chiều không gian bởi tầng Global Pooling.

6.2.2 Cơ chế hoạt động của CBAM

Module CBAM được triển khai trong kiến trúc hoạt động như một bộ lọc thông tin kép, tuần tự tinh chỉnh tensor đặc trưng đầu vào qua hai phân hệ:

- **Module Channel Attention:** Đóng vai trò giúp mạng trả lời câu hỏi "*Đặc trưng nào (what) là quan trọng?*". Đầu tiên, module áp dụng đồng thời *AdaptiveAvgPool2d* và *AdaptiveMaxPool2d* lên bản đồ đặc trưng. Các kết quả này được đưa qua một mạng MLP với các trọng

số chia sẻ (shared weights) để học được mối tương quan giữa các kênh. Cuối cùng, tổng của chúng được đi qua hàm Sigmoid để tạo ra vector trọng số kênh, giúp nhấn mạnh các bộ lọc (filters) mang thông tin nhận dạng khuôn mặt và triệt tiêu các bộ lọc dư thừa.

- **Module Spatial Attention:** Hỗ trợ mạng trả lời câu hỏi "*Vị trí nào (where) là quan trọng?*". Tensor sau khi qua Channel Attention tiếp tục được gộp thông tin dọc theo trục kênh bằng phép toán trung bình và cực đại, tạo thành một bản đồ đặc trưng 2 chiều kênh. Một tầng tích chập với kích thước kernel lớn (7×7) được áp dụng để bao quát ngữ cảnh không gian, kết hợp với hàm Sigmoid để tạo ra ma trận chú ý không gian 2D. Quá trình này làm nổi bật các vùng chứa đặc điểm nhận diện (mắt, mũi, miệng) và làm mờ phông nền hay các vùng bị che khuất.

6.2.3 Cấu trúc luồng dữ liệu của FaceNet128d_Attention_V2

Sự khác biệt làm nên tính hiệu quả của kiến trúc cải tiến nằm ở vị trí đặt module CBAM và quy trình biến đổi dữ liệu, gồm 4 giai đoạn chính:

1. **Spatial Feature Extraction:** Thay vì coi toàn bộ *Inception-ResNet-v1* như một hộp đen, mô hình đề xuất bóc tách và trích xuất dữ liệu dừng lại ngay tại **block8**. Đầu ra tại bước này là một tensor chứa các đặc trưng không gian sâu với kích thước $(B, 1792, H', W')$.
2. **Attention Mechanism:** Tensor đặc trưng 1792 kênh được đưa trực tiếp qua module *CBAM*. Thông qua cơ chế tích vô hướng tuần tự với trọng số kênh và không gian, các đặc trưng được tinh chỉnh để đạt độ tập trung cao nhất vào các thành phần định danh cốt lõi của khuôn mặt.
3. **Global Pooling:** Chỉ sau khi đã được chất lọc bởi CBAM, bản đồ đặc trưng mới đi qua tầng *Global Average Pooling* (**avgpool_1a**) và hàm *Dropout*, sau đó được là phẳng (flatten) thành một vector đặc trưng có số chiều là 1792.
4. **Embedding & Classification:** Vector 1792 chiều mang tính phân biệt cao (highly discriminative) lúc này mới được chiếu qua tầng Linear để nén xuống không gian nhúng 128 chiều. Các hàm kích hoạt *ReLU* và *Dropout* ($p = 0.3$) tiếp tục được áp dụng trước khi đưa logits vào tầng phân loại cuối cùng.

Tóm lại, bằng cách di dời điểm nén thông tin ra phía sau cơ chế chú ý 2D (CBAM), vector nhúng $\mathbb{R}^{128}$ tuy bị giới hạn về kích thước vật lý nhưng lại bảo toàn được hàm lượng thông tin định dạng cực kỳ phong phú. Nhờ đó, mô hình cải thiện rõ rệt khả năng kháng nhiễu và tăng cường độ chính xác cho bài toán nhận dạng khuôn mặt.

6.3 Thực nghiệm

6.3.1 Cấu hình thực nghiệm

Nhóm thực hiện thực nghiệm trên GPU T4 của Google Colab với cấu hình như sau:

- **GPU:** NVIDIA Tesla T4 với 16GB VRAM (GDDR6), hỗ trợ công nghệ Tensor Core tối ưu hóa cho các phép toán học sâu.
- **CPU:** Intel Xeon Processor @ 2.20GHz (được cấp phát 2 vCPU).
- **RAM hệ thống:** Khoảng 12.7 GB.
- **Ổ cứng lưu trữ (Disk):** Khoảng 78 GB dung lượng lưu trữ khả dụng.
- **Môi trường phần mềm:** Môi trường cài đặt sẵn hệ điều hành Ubuntu 22.04 LTS, Python 3.10, CUDA Toolkit 12.x và các thư viện học máy phổ biến (như PyTorch, torchvision).

6.3.2 Dữ liệu thực nghiệm

Để đánh giá hiệu năng của kiến trúc đề xuất, nhóm sử dụng bộ dữ liệu khuôn mặt nổi tiếng **LFW**. Quá trình chuẩn bị và tiền xử lý dữ liệu được thực hiện với các bước cụ thể như sau:

- **Lựa chọn dữ liệu:** Nhằm đảm bảo mô hình có đủ mẫu cho quá trình học và hội tụ tốt, nhóm thiết lập điều kiện chỉ trích xuất các cá nhân có ít nhất 30 bức ảnh (`min_faces_per_person=30`).
- **Tiền xử lý ảnh:**
 - Ảnh gốc từ tập LFW (ảnh đa cấp xám, kích thước ban đầu 62x47) được đưa về dải giá trị chuẩn từ 0 đến 255 với kiểu dữ liệu `uint8`.
 - Mặc dù là ảnh xám, dữ liệu được chuyển đổi sang định dạng RGB (3 kênh màu) thông qua thư viện PIL nhằm đảm bảo tính tương thích với kích thước tensor đầu vào của mạng cơ sở Inception-ResNet-v1.
 - Ảnh sau đó được thay đổi kích thước về chuẩn 160x160 pixel.
- **Tăng cường và Chuẩn hóa dữ liệu:**
 - Kỹ thuật tăng cường dữ liệu nhẹ được áp dụng thông qua phép lật ngang ảnh ngẫu nhiên (*Random Horizontal Flip*) để tăng tính đa dạng cho tập mẫu và hạn chế hiện tượng overfitting.
 - Dữ liệu sau đó được chuyển thành dạng Tensor và chuẩn hóa. Phép toán này giúp ánh xạ các giá trị pixel vào dải $[-1, 1]$, tạo điều kiện thuận lợi cho việc cập nhật trọng số của thuật toán tối ưu.

- **Phân chia tập dữ liệu:** Toàn bộ tập dữ liệu thỏa mãn điều kiện được chia thành hai phần: Tập huấn luyện (Train set) chiếm 80% và Tập xác thực (Validation set) chiếm 20%. Phân chia được cố định bằng `random_state=42` để đảm bảo tính tái lập của thực nghiệm.
- **Cấu hình nạp dữ liệu:** Dữ liệu được đưa vào mạng thông qua cấu trúc DataLoader với *batch size* là 16. Batch size nhỏ được lựa chọn một cách có chủ đích nhằm cân bằng giữa việc học đặc trưng trên ảnh kích thước lớn (160x160) và giới hạn bộ nhớ VRAM của thiết bị phần cứng.

6.3.3 Kết quả thực nghiệm

Bảng 9: So sánh số lượng tham số và hiệu năng giữa các mô hình trên tập kiểm thử

Kiến trúc mô hình	# Params (M)	Accuracy	Precision	Recall	F1-Score
FaceNet128d (Baseline)	27.98	0.96	0.95	0.93	0.96
FaceNet128d + CBAM	23.20	0.97	0.97	0.96	0.95

6.4 Đánh giá

Dựa trên kết quả thực nghiệm được thống kê tại Bảng 9, chúng ta có thể rút ra những đánh giá quan trọng về sự chênh lệch hiệu năng cũng như độ phức tạp tính toán giữa kiến trúc cơ sở và kiến trúc đề xuất:

- **Tối ưu hóa không gian lưu trữ và tính toán:** Một điểm sáng đáng chú ý trong kết quả là mô hình đề xuất tích hợp CBAM lại có số lượng tham số thấp hơn (23.20 triệu so với 27.98 triệu tham số của mạng baseline). Sự sụt giảm khoảng 17% số lượng tham số này xuất phát từ chiến lược bóc tách mạng gốc, dùng trích xuất đặc trưng sớm tại `block8` kết hợp với kỹ thuật pooling mới. Điều này chứng minh rằng việc chèn thêm module Attention (CBAM) tuy làm tăng thêm một vài phép toán cục bộ nhưng tổng thể kiến trúc lại trở nên nhẹ nhàng, tinh gọn và tối ưu bộ nhớ VRAM hơn đáng kể.
- **Cải thiện khả năng định danh (Accuracy, Precision & Recall):** Mặc dù có số lượng tham số ít hơn, mô hình FaceNet128d + CBAM lại vượt trội mạng baseline ở các chỉ số quan trọng nhất. Độ chính xác tổng thể tăng lên 0.97 (so với 0.96). Đặc biệt, chỉ số Precision đạt 0.97 và Recall đạt 0.96 (tăng mạnh từ 0.93). Sự gia tăng ấn tượng của Recall cho thấy cơ chế chú ý không gian và kênh của CBAM đã làm rất tốt nhiệm vụ xác định các đặc trưng cốt lõi của khuôn mặt, giúp mô hình giảm thiểu đáng kể số lượng mẫu bị nhận diện sai (False Negatives) do các yếu tố nhiễu như góc mặt hay điều kiện ánh sáng.
- **Đánh giá sự đánh đổi (F1-Score Trade-off):** Dữ liệu cho thấy chỉ số F1-Score của mô hình đề xuất (0.95) có sự suy giảm nhẹ so với mô hình gốc (0.96). Về mặt toán học, điều này

phản ánh sự dịch chuyển trong cách phân phối độ tin cậy của mô hình trên các lớp dữ liệu cụ thể (có thể bị ảnh hưởng bởi cách tính trung bình macro/micro trên tập validation). Tuy nhiên, xét trên tổng thể bài toán nhận dạng khuôn mặt (ưu tiên việc nhận diện đúng (Recall cao) và từ chối sai (Precision cao)) mức F1-Score 0.95 vẫn là một kết quả xuất sắc.

6.5 Kết luận

Việc tích hợp module CBAM vào kiến trúc FaceNet128d không chỉ giải quyết thành công bài toán thất thoát thông tin không gian mà còn mang lại tác động kép: vừa thu gọn kích thước mô hình, vừa nâng cao độ chính xác và khả năng truy hồi đặc trưng. Những kết quả này khẳng định tính đúng đắn và tiềm năng ứng dụng thực tiễn cao của phương pháp đề xuất.

7 Kết luận và hướng phát triển trong tương lai xa

7.1 Kết luận

Trong đề án này, nhóm đã đi sâu nghiên cứu và thực nghiệm bài toán nhận dạng khuôn mặt trên miền dữ liệu mã hóa, một trong những hướng tiếp cận quan trọng nhất để bảo vệ quyền riêng tư hiện nay. Bắt đầu từ việc phân tích nền tảng lý thuyết của *Blind Vision* với cơ chế Tính toán đa bên an toàn (SMPC), đề án đã làm rõ sự dịch chuyển công nghệ sang các hệ thống sử dụng Mã hóa đồng hình toàn phần (FHE) hiện đại thông qua bài báo *CryptoFace* và *Cipher Face* [1], [16]. Không dừng lại ở việc tìm hiểu lý thuyết, nhóm đã tiến hành triển khai thực nghiệm thành công framework *Cipher Face* trên hai bộ dữ liệu LFW và PFR, từ đó đánh giá khách quan về hiệu năng tính toán cũng như độ chính xác của quá trình suy luận trên dữ liệu mã hóa [6]. Đặc biệt, nhóm đã đề xuất cải tiến mạng cơ sở FaceNet128d bằng cách tích hợp cơ chế chú ý *CBAM* (*Convolutional Block Attention Module*) [17]. Kết quả thực nghiệm cho thấy mô hình FaceNet128d + CBAM không chỉ duy trì và vượt trội hơn về các chỉ số đánh giá (Accuracy, Precision, Recall, F1-Score) mà còn giảm thiểu đáng kể số lượng tham số từ 27.98M xuống 23.20M, tối ưu hóa không gian lưu trữ và phù hợp hơn cho các hệ thống đòi hỏi độ phức tạp tính toán thấp.

7.2 Hướng phát triển trong tương lai xa

Mặc dù đã đạt được những kết quả khả quan, hệ thống nhận dạng khuôn mặt bảo mật sinh trắc học vẫn còn nhiều dư địa để tối ưu và phát triển. Trong tương lai xa, nhóm đề xuất các hướng nghiên cứu cụ thể sau:

- **Lai ghép FHE và MPC (Multi-Party Computation):** Sử dụng mô hình kết hợp, trong đó FHE đảm nhiệm các phần tính toán nặng (Convolution, Linear) nhằm tiết kiệm băng thông giao tiếp, còn MPC xử lý các phép toán yêu cầu bộ nhớ cao hoặc các phép toán phi

tuyến phức tạp (Activation, Pooling). Giải pháp này giúp giảm đáng kể lượng RAM tiêu tốn trong suốt quá trình suy luận.

- **Tích hợp kiến trúc FaceNet128d + CBAM vào môi trường mã hóa toàn phần:** Đưa kiến trúc FaceNet128d tích hợp CBAM (vốn đã chứng minh hiệu quả giảm tham số trên miền bản rõ) vào pipeline của Cipher Face. Điều này đòi hỏi quá trình chuyển đổi các hàm kích hoạt và cơ chế Attention thành các xấp xỉ đa thức phù hợp với nền tảng FHE.
- **Neural Architecture Search (NAS) cho FHE:** Sử dụng kỹ thuật tìm kiếm tự động để thiết kế các kiến trúc mạng nơ-ron chuyên biệt phù hợp với FHE (Privacy-Preserving CNNs). Mục tiêu là tìm ra các kiến trúc có khả năng trích xuất đặc trưng tốt nhất nhưng vẫn giữ được độ sâu nhân ở mức thấp nhất, lý thuyết có thể tăng cường độ chính xác cho hệ thống mã hóa.
- **Tối ưu hóa linh hoạt các tham số mã hóa:** Phát triển cơ chế điều chỉnh tự động các tham số lược đồ mã hóa (như n, q, g) để cân bằng giữa chi phí tính toán và độ bảo mật. Việc điều chỉnh này sẽ giúp hệ thống dễ dàng thích ứng từ môi trường phần cứng hạn chế (thiết bị biên/nhúng) cho đến các hệ thống tính toán đám mây.

8 Lời cảm ơn

Em xin cảm ơn thầy **Lê Hoàng Thái**, thầy **Võ Thanh Lâm** và thầy **Nguyễn Thanh Tình** đã giúp đỡ, và giải đáp thắc mắc của nhóm trong quá trình học cũng như trong quá trình làm đồ án này.

Đồ án này có sự hỗ trợ của Chat-GPT, Gemini, AlphaXiv trong quá trình tổng hợp thông tin và viết LaTeX.

9 Phụ lục

9.1 Ghi chú về cách dùng AI

- **Gemini.** *Gemini 3 Pro, Google, gemini.google.com*, truy cập vào buổi sáng 27/02/2026, prompt: "Tôi muốn hiểu paper CryptoFace này, hãy viết lại cho tôi giống như bài individual nhận dạng ấy (23127354 (1).pdf) Phần 1 tổng quan về giải pháp: Ở phần 1.1 vấn đề cần giải quyết, hãy đưa ra cho tôi các vấn đề mà paper này nêu ra sau đó hãy kết luận CryptoFace giải quyết các vấn đề đó như thế nào giống như bài individual ấy, 1.2 cũng dựa trên bài individual mà làm, 1.3 thì kiểu chia làm 2 trường hợp: Nếu paper có tiền thân của nó thì nêu tiền thân của nó rồi dần dần đến cryptoface hiện tại, 2 thì nếu không có tiền thân hãy nêu lịch sử phát triển có nó ra, ví dụ như nó là kế thừa paradigms của blind vision xong từ fhe đó pt đến cryptoface hiện đại, ở mỗi giai đoạn gặp những thách thức nào, và có điểm đột phá gì, cải thiện được cái thách thức ở giai đoạn cũ không nêu hết ra, nhớ có giải thích cả paradigm là gì nữa, các phần sau cũng dựa trên individual mà làm, Ở phần thuật toán cốt lõi bạn hãy nêu cho tôi thêm là các thuật toán đó liên quan đến kiến thức gì nữa để tôi tiện nghiên cứu, học hỏi thêm vì tôi không có kiến thức đến bảo mật cái task này chủ yếu để cho tôi đọc hiểu, nên nếu có gì cần bổ sung để hỗ trợ tôi đọc hiểu bạn cứ thoải mái thêm vào, không cần phải quá máy móc, tôi muốn theo format trên vì nếu theo kiểu đó nó dễ đọc hiểu thôi bạn đã rõ chưa? Có gì cần bổ sung cứ nói thêm với tôi" Mục đích là để tóm tắt sơ bộ nội dung paper, sau đó sinh viên có kiểm chứng lại trên paper gốc, đồng thời tổng hợp thông tin về paradigm của bài toán."
- **Gemini.** *Gemini 3 Pro, Google, gemini.google.com*, truy cập vào buổi sáng 27/02/2026, prompt: "Hiểu kiểu paradigm có nghĩa là phải làm rõ các ý sau (gợi ý):
Thực thể tham gia (Entities): Alice là ai (Client), Bob là ai (Server)?
Mục tiêu bảo mật (Security Goals): Alice muốn giấu cái gì? Bob cần bảo vệ cái gì?
Luồng tương tác (Flow): Tại sao dữ liệu lại đi như thế này mà không đi như thế kia? Tại sao lại dùng mã hóa ở bước này?
Sự dịch chuyển (Shift): Tại sao cách làm này (Blind Vision) lại khác biệt hoàn toàn so với cách nhận diện khuôn mặt truyền thống?"

Paradigm của Blind vision : Nhìn mà không thấy

Trong thị giác máy tính bảo mật, Blind Vision là một khuôn mẫu cho phép thực hiện nhận diện trên dữ liệu đã mã hóa mà không làm lộ thông tin nhạy cảm của các bên:

Alice (Client): Giữ ảnh gốc, không muốn tiết lộ dữ liệu thô cho Server.

Bob (Server): Giữ thuật toán (trọng số/bộ lọc), không muốn tiết lộ sở hữu trí tuệ cho Client.

Kết quả: Bob tính toán nhưng không biết kết quả nhận diện là gì; chỉ Alice (người giữ khóa) mới biết kết quả cuối cùng.

Còn thiếu luồng tương tác và sự dịch chuyển

như bạn đã thấy phần take note trên còn thiếu flow và shift, bạn hãy cho tôi biết luồng của nó là gì? Sau đó trả lời các câu hỏi trong ý flow đó, rồi làm tương tự với shift". Kiểm chứng với AI về tài liệu tổng hợp được qua đó tham khảo thêm ý kiến AI về paradigm của blind vision."

- **Gemini.** *Gemini 3 Pro, Google, gemini.google.com*, truy cập vào buổi sáng 01/03/2026, prompt: "Do giới hạn tính toán của SMPC, Alice sử dụng bộ lọc HoG (Histogram of Oriented Gradients) để tìm nhanh các vùng cửa sổ (windows) có khả năng chứa khuôn mặt, nhằm giảm thiểu lượng dữ liệu phải đưa vào miền mã hóa.

bạn nói vậy là alice có sài smpc không hay sài hog hay là dùng cả 2?" Hỏi AI để làm rõ hơn quy trình xử lý trong Blind Vision."
- **Gemini.** *Gemini 3 Pro, Google, gemini.google.com*, truy cập vào buổi sáng 01/03/2026, prompt: "Đây là tài liệu của Chapter 27 Privacy Protection and Face Recognition mà nhóm tôi tổng hợp được hãy giúp tôi viết mục 1.1 và 2.3, chỉ cần nội dung thôi không cần khai báo thư viện, viết bằng latex". Nhờ AI sinh nội dung dựa trên những tài liệu nhóm tổng hợp được, sau đó có tự viết lại và nhờ AI format sau cho văn phong khoa học, chuyên nghiệp, đồng thời đối chiếu với tài liệu gốc trong sách."
- **ChatGPT.** *ChatGPT thường, OpenAI, chatgpt.com*, prompt: "Hệ thống có khả năng thực hiện phép chiếu một hình ảnh truy vấn (query image) lên không gian eigenvector và tính toán khoảng cách đến các khuôn mặt đã đăng ký hoàn toàn trong môi trường mã hóa. Quá trình này đảm bảo bên truy vấn không phải tiết lộ ảnh gốc, và bên lưu trữ cũng không phải lộ cơ sở dữ liệu khuôn mặt. không gian eigenvector đề nhắc đến ở đây là gì?" Hỏi về eigenvector trong Blind Vision Prompt: "Tức là chúng ta ban đầu có x,y,z như những đặc trưng mất phải mất trái gì đó hay 1 pixel? và dùng công $1/n-1$ nhân cho tổng của các phép tính x trừ tb nhân y trừ tb làm $cov(x,y)$, $cov(x,z)$,... tương ứng thu được các eigenvector à? và w là tọa độ là sao, tọa độ gồm x và y hoặc RGB mà tại sao lại có 1 giá trị w vậy? và giá trị pixel i,j trên nhiều ảnh là sao tôi chưa hiểu lắm, là nó thiết lập 1 hệ giá trị dựa trên các pixel ở cùng vị trí đó

hay là có sẵn 1 hệ giá trị luôn?" Đối chứng với AI về kiến thức mình hiểu và hỏi thêm 1 số phần còn chưa hiểu"

- **Gemini.** *Gemini 3 Pro, Google, gemini.google.com*, truy cập vào buổi sáng 24/02/2026, prompt: "Tổng hợp tất cả tài liệu của chương sách này, nhớ nhấn mạnh các kỹ thuật có trong đây, đặc biệt chú ý phần Blind Vision vì đây là trọng tâm làm bài của nhóm tôi hãy viết cho tôi 1 bức tranh toàn cảnh về bảo mật rồi dẫn dắt tại sao người ta lại cần bảo mật bằng mã hóa, rồi dẫn dắt qua Blind Vision, cho tôi biết key value của Blind Vision là gì paradigm của nó là gì?" Tổng hợp tài liệu về chương sách, sau đó sinh viên đối chiếu từng thông tin về chương sách đó, chỉnh sửa, biên soạn lại sao cho dễ đọc, và có thể dùng trong báo cáo"

Tài liệu

- [1] Wei Ao and Vishnu Naresh Boddeti. Cryptoface: End-to-end encrypted face recognition. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 19197–19206, June 2025.
- [2] Shai Avidan and Moshe Butman. Blind vision. In Aleš Leonardis, Horst Bischof, and Axel Pinz, editors, *Computer Vision – ECCV 2006*, volume 3953 of *Lecture Notes in Computer Science*, pages 1–13. Springer, Berlin, Heidelberg, 2006.
- [3] Amina Bassit, Florian Hahn, Zohra Rezgui, Una Kelly, Raymond Veldhuis, and Andreas Peter. Template recovery attack on homomorphically encrypted biometric recognition systems with unprotected threshold comparison. In *2023 IEEE International Joint Conference on Biometrics (IJCB)*, pages 1–10, 2023.
- [4] Burak. Pins face recognition dataset. <https://www.kaggle.com/datasets/hereisburak/pins-face-recognition>, 2018. Accessed: 2026-04-20.
- [5] Jung Hee Cheon, Kyoohyung Han, Andrey Kim, Miran Kim, and Yongsoo Song. A full rns variant of approximate homomorphic encryption. In *Selected Areas in Cryptography – SAC 2018*, volume 11349 of *Lecture Notes in Computer Science*, pages 347–368. Springer, 2018.
- [6] Jung Hee Cheon, Andrey Kim, Miran Kim, and Yongsoo Song. Homomorphic encryption for arithmetic of approximate numbers. In *Advances in Cryptology – ASIACRYPT 2017*, volume 10624 of *Lecture Notes in Computer Science*, pages 409–437. Springer, 2017.
- [7] Debayan Deb, Jianbang Zhang, and Anil K. Jain. Advfaces: Adversarial face synthesis. In *2020 IEEE International Joint Conference on Biometrics (IJCB)*, pages 1–10. IEEE, 2020.
- [8] Jiankang Deng, Jia Guo, Jing Yang, Niannan Xue, Irene Kotsia, and Stefanos Zafeiriou. Arcface: Additive angular margin loss for deep face recognition. *arXiv*, abs/1801.07698, 2018.
- [9] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale. *arXiv preprint arXiv:2010.11929*, 2020.
- [10] Tobias Goodwin-Allcock, Ting Gong, Robert Gray, Parashkev Nachev, and Hui Zhang. Patch-cnn: Training data-efficient deep learning for high-fidelity diffusion tensor estimation from minimal diffusion protocols, 2023.
- [11] Shai Halevi and Victor Shoup. Algorithms in helib. In *Advances in Cryptology – CRYPTO 2014*, pages 554–571. Springer, 2014.

- [12] Jiazhen Ji, Huan Wang, Yuge Huang, Jiaxiang Wu, Xingkun Xu, Shouhong Ding, ShengChuan Zhang, Liujuan Cao, and Rongrong Ji. Privacy-preserving face recognition with learnable privacy budgets in frequency domain. In Shai Avidan, Gabriel J. Brostow, Moustapha Cissé, Giovanni Maria Farinella, and Tal Hassner, editors, *Computer Vision – ECCV 2022*, volume 13672 of *Lecture Notes in Computer Science*, pages 475–491. Springer, Cham, 2022.
- [13] Qian Lou and Lei Jiang. Hemet: A homomorphic-encryption-friendly privacy-preserving mobile neural network architecture. In Marina Meil{a} and Tong Zhang, editors, *Proceedings of the 38th International Conference on Machine Learning*, volume 139 of *Proceedings of Machine Learning Research*, pages 7102–7110. PMLR, 2021.
- [14] Yuxi Mi, Zhizhou Zhong, Yuge Huang, Jiazhen Ji, Jianqing Xu, Jun Wang, Shaoming Wang, Shouhong Ding, and Shuigeng Zhou. Privacy-preserving face recognition using trainable feature subtraction. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 297–307, June 2024.
- [15] Jaiyoung Park, Michael Jaemin Kim, Wonkyung Jung, and Jung Ho Ahn. Aespa: Accuracy preserving low-degree polynomial activation for fast private inference, 2022.
- [16] Sefik Ilkin Serengil and Alper Ozpinar. Cipherface: A fully homomorphic encryption-driven framework for secure cloud-based facial recognition. *arXiv preprint arXiv:2502.18514*, 2025.
- [17] Sanghyun Woo, Jongchan Park, Joon-Young Lee, and In So Kweon. Cbam: Convolutional block attention module. In *Proceedings of the European Conference on Computer Vision (ECCV)*, pages 3–19, 2018.